



UNIVERSIDAD
DE GRANADA

TRABAJO FIN DE GRADO
INGENIERÍA INFORMÁTICA

Bastionado de modelos de Inteligencia Artificial generativa en entornos corporativos basado en técnicas de *red teaming*

Configuración de aplicaciones de IA enfocada a la seguridad
de la corporación

Autor

Alejandro Muñoz Gutiérrez

Directores

Dr. D. Pedro García Teodoro

D. Daniel González López (Director de Ciberseguridad, INNOVASUR)



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍAS INFORMÁTICA Y DE
TELECOMUNICACIÓN

Granada, 31 de agosto de 2026

Bastionado de modelos de Inteligencia Artificial generativa en entornos corporativos basado en técnicas de *red teaming*

Configuración de aplicaciones de IA en la seguridad de la
corporación.

Autor

Alejandro Muñoz Gutiérrez

Directores

Dr. D. Pedro García Teodoro

D. Daniel González López (Director de Ciberseguridad, INNOVASUR)

Declaración de autoría del presente trabajo

Alejandro Muñoz Gutiérrez

Yo, Alejandro Muñoz Gutiérrez, declaro que el presente Trabajo de Fin de Grado, titulado *Bastionado de modelos de Inteligencia Artificial generativa en entornos corporativos basado en técnicas de red teaming* realizado por mí de forma personal bajo la supervisión de los directores indicados, y que el contenido aquí presentado es original salvo las referencias explícitamente citadas a lo largo del documento.

Durante el desarrollo de este trabajo he hecho uso de herramientas de Inteligencia Artificial generativa como apoyo en determinadas tareas. Concretamente, estas herramientas han sido utilizadas en los siguientes contextos:

- **Redacción de partes del documento:** algunas secciones del texto han sido reescritas con asistencia de modelos de lenguaje para adecuar el lenguaje a una base técnica apropiada al trabajo.
- **Escritura de fragmentos de código:** en determinados módulos del sistema desarrollado se ha recurrido a herramientas de generación de código como apoyo en la implementación, siempre bajo mi criterio en cuanto al diseño, la integración y la verificación del funcionamiento.
- **Resolución de errores:** durante el proceso de desarrollo y testing se han utilizado estas herramientas para diagnosticar y corregir errores, actuando como un recurso de depuración complementario a mi propio análisis.
- **Generación de *prompts* adversariales:** en el contexto de las campañas de AI *Red Teaming* descritas, se han empleado modelos de lenguaje como herramienta para generar y diversificar los *prompts* maliciosos utilizados en los experimentos, lo cual forma parte integral de la metodología del trabajo y está debidamente documentado en el cuerpo del mismo.

En todos los casos, el uso de estas herramientas ha sido consciente, supervisado y subordinado a mis propias decisiones técnicas y metodológicas. La responsabilidad sobre el diseño del sistema, la interpretación de los resultados, las conclusiones alcanzadas y la integridad global del trabajo es exclusivamente mía.

Granada, 31 de agosto de 2026.

Bastionado de modelos de Inteligencia Artificial generativa en entornos corporativos basado en técnicas de *red teaming*: Configuración de aplicaciones de IA en la seguridad de la corporación.

Alejandro Muñoz Gutiérrez

Palabras clave: Seguridad en Inteligencia Artificial, Modelos de Lenguaje de Gran Escala (LLM), Configuración de seguridad, Endurecimiento

Resumen

La integración masiva de modelos de Inteligencia Artificial (IA) generativa, como **Microsoft 365 Copilot**, en los flujos de trabajo corporativos ha introducido una superficie de ataque semántica que trasciende los perímetros de seguridad tradicionales. El riesgo crítico reside en el fenómeno del *oversharing* o compartición excesiva de datos, donde los asistentes de IA, al operar bajo la identidad del usuario, pueden acceder, resumir y exfiltrar información sensible debido a una gestión de permisos deficiente en el entorno SaaS. El presente Trabajo de Fin de Grado aborda la problemática del bastionado de cuentas y proyectos en entornos de productividad en la nube desde una perspectiva adversarial, analizando las vulnerabilidades tipificadas por el marco OWASP Top 10 para Aplicaciones LLM y las tácticas de ataque documentadas en la matriz MITRE ATLAS. Auditar manualmente cada despliegue de IA se ha vuelto simplemente inviable dada la escala que están alcanzando estos sistemas. Por eso se propone una metodología de endurecimiento automatizado, pensada para detectar y mitigar riesgos de fuga de datos antes de que se conviertan en un problema real.

La metodología emula al adversario mediante la herramienta de código abierto **PyRIT** (*Python Risk Identification Tool*). En lugar de *jailbreaks* o inyecciones complejas, la campaña recurre a la enumeración directa por *oversharing*: peticiones benignas de un solo turno que solicitan al asistente inventariar y recuperar contenido del *tenant*. El éxito de cada intento se determina de forma determinista, comprobando si **Copilot** cita ficheros reales de la organización en sus atribuciones de *grounding*; la gravedad se estima con un *scorer* de privacidad.

Como contribución principal, se presenta una herramienta que interpreta automáticamente los resultados de **PyRIT**, analiza las causas raíz de los ataques exitosos y genera recomendaciones de bastionado priorizadas en tres niveles: cuenta (ajuste de *scopes* de identidad y MFA), proyecto (corrección de la herencia de permisos en **SharePoint** u **OneDrive**) y postura de seguridad global (reglas de DLP y etiquetas de sensibilidad). Cada plan se

acompaña de una estimación determinista —y orientativa, al basarse en parámetros heurísticos— de la reducción de riesgo esperable por fases.

Artificial Intelligence generative models bastion in corporate environments based on attacks: AI applications configuration focused on corporation security

Alejandro Muñoz Gutiérrez

Keywords: Artificial Intelligence security, Large Language Models (LLM), Security configuration, Hardening


Abstract

The widespread integration of Generative AI (GenAI) models, such as **Microsoft 365 Copilot**, into corporate workflows has introduced a semantic attack surface that extends beyond traditional security perimeters. A critical risk in these ecosystems is the phenomenon of data oversharing, where AI assistants, operating under the user's identity, can access, summarize, and exfiltrate sensitive information due to poorly governed permissions within the SaaS environment. This Bachelor's Thesis addresses the hardening of accounts and projects in cloud productivity suites from an adversarial perspective, analyzing vulnerabilities categorized by the OWASP Top 10 for LLM Applications and attack tactics documented in the MITRE ATLAS matrix. Given the infeasibility of manual audits at the scale of current AI deployments, this work proposes an automated hardening methodology to proactively identify and mitigate data leakage risks.

The methodology emulates the adversary with the open-source tool **PyRIT** (*Python Risk Identification Tool*). Rather than *jailbreaks* or complex injections, the campaign relies on direct enumeration by *oversharing*: benign, single-turn requests that ask the assistant to inventory and retrieve *tenant* content. Success is measured deterministically by checking whether **Copilot** cites real organizational files in its *grounding* attributions; severity is estimated with a *privacy scorer*.

As its main contribution, the thesis presents a tool that automatically interprets **PyRIT** results, analyzes the root causes of successful attacks, and generates prioritized hardening recommendations across three levels: account (identity *scopes* and MFA), project (permission inheritance in **SharePoint** or **OneDrive**), and global posture (DLP rules and sensitivity labels). Each plan includes a deterministic —and indicative, being heuristic-based— estimate of the expected per-phase risk reduction.

Yo, **Alejandro Muñoz Gutiérrez**, alumno de la titulación Grado en Ingeniería Informática de la **Escuela Técnica Superior de Ingenierías Informática y de Telecomunicación de la Universidad de Granada**, con DNI 77992887W, autorizo la ubicación de la siguiente copia de mi Trabajo Fin de Grado en la biblioteca del centro para que pueda ser consultada por las personas que lo deseen.

A handwritten signature in black ink, reading 'Alejandro', enclosed within a large, stylized oval loop.

Fdo: Alejandro Muñoz Gutiérrez

Granada, 31 de agosto de 2026.

D. **Pedro García Teodoro**, Profesor del Área de Ingeniería Telemática del Departamento de Teoría de la Señal, Telemática y Comunicaciones de la Universidad de Granada.

D. **Daniel González López**, Director de Ciberseguridad de Innovasur.

Informan:

Que el presente trabajo, titulado *Bastionado de modelos de Inteligencia Artificial generativa en entornos corporativos basado en técnicas de red teaming: Configuración de aplicaciones de IA enfocada a la seguridad de la corporación*, ha sido realizado bajo su supervisión por **Alejandro Muñoz Gutiérrez**, y autorizamos la defensa de dicho trabajo ante el tribunal que corresponda.

Y para que conste, expiden y firman el presente informe en Granada, a 31 de agosto de 2026.

Los Directores:

GARCIA
TEODORO
PEDRO -
26469380
Z

Firmado
digitalmente por
GARCIA
TEODORO PEDRO
- 26469380Z
Fecha: 2026.09.01
12:06:05 +02'00'

Firmado por GONZALEZ
LOPEZ DANIEL - ***3573**
el día 01/09/2026 con un
certificado emitido por
AC FNMT Usuarios

Dr. D. Pedro García Teodoro

D. Daniel González López

Agradecimientos

Gracias a todas las personas que han estado implicadas en el desarrollo de este trabajo.

Gracias a mis tutores Pedro y Daniel por haberme guiado y prestado su experiencia y conocimientos. Su apoyo ha sido vital en la realización de este trabajo.

Gracias a Innovasur por los recursos que han permitido el desarrollo de este trabajo.

Gracias a mis padres y a mi hermana por su apoyo y confianza.

Gracias a mis amigos por su compañía a lo largo de todo este proceso.

Gracias a mis sobrinos Martina y Lucas que han sido mi motivación durante todo este tiempo.

Índice general

1. Motivación	1
1.1. Contexto	1
1.2. Motivación del estudio	2
1.3. Objetivos	3
1.3.1. Objetivo general	3
1.3.2. Objetivos específicos	3
1.4. Organización de la memoria	4
2. Planificación	6
2.1. Alcance del estudio	6
2.2. Requisitos técnicos del entorno	6
2.2.1. Requisitos de software y dependencias	7
2.2.2. Configuración del <i>tenant</i> de pruebas	7
2.3. Especificación de requisitos funcionales y no funcionales	7
2.3.1. Requisitos funcionales (RF)	7
2.3.2. Requisitos no funcionales (RNF)	7
2.4. Análisis de riesgos de la implementación	9
2.5. Planificación temporal y estimación de esfuerzo	9
2.5.1. Parámetros generales de la planificación	9
2.5.2. Desglose mensual de actividades	11
2.5.3. Diagrama de Gantt	13
2.5.4. Herramientas y entorno de trabajo	13
2.5.5. Consideraciones sobre la reproducibilidad	15
2.5.6. Análisis de coste económico	15
3. Estado del arte	17
3.1. Contexto actual y evolución de los LLM hacia arquitecturas agénticas	17
3.2. Marcos de referencia y estándares en seguridad de IA	18
3.2.1. NIST AI <i>Risk Management Framework</i>	18
3.2.2. OWASP Top 10 for LLM and <i>Agentic Applications</i>	19
3.2.3. MITRE ATLAS: tácticas y técnicas en sistemas de IA	20
3.3. Taxonomía de amenazas en arquitecturas agénticas con LLM	21

3.3.1.	Inyección de <i>prompts</i> : directa e indirecta	21
3.3.2.	Uso indebido de herramientas (<i>Tool Misuse</i>)	22
3.3.3.	Exceso de agencia (<i>Excessive Agency</i>)	22
3.3.4.	Denegación de servicio semántica (SDoS)	23
3.4.	Mecanismos de defensa: <i>hardening</i> del <i>system prompt</i>	24
3.4.1.	Niveles de endurecimiento y su impacto operativo	24
3.4.2.	Entornos de ejecución local y reproducibilidad de <i>benchmarks</i>	25
3.4.3.	Limitaciones de los mecanismos basados en <i>system</i> <i>prompt</i>	26
3.5.	Síntesis crítica y motivación de la investigación	26
4.	Diseño de la propuesta	28
4.1.	Descripción general del sistema	28
4.1.1.	Componentes nucleares	28
4.2.	Arquitectura del sistema y flujo de datos	29
4.2.1.	Fases del ciclo de vida de una auditoría	30
4.3.	Diseño detallado del motor de recomendación	31
4.3.1.	Algoritmo de priorización de hallazgos	31
4.4.	Introducción y justificación del diseño	32
4.4.1.	Por qué no extender PyRIT directamente	32
4.4.2.	Justificación del uso de Azure OpenAI	32
4.5.	Arquitectura general del sistema	32
4.5.1.	Capa 1: Entrada y validación	33
4.5.2.	Capa 2: Análisis mediante IA	33
4.5.3.	Capa 3: Scoring determinista	34
4.5.4.	Capa 4: Salida y persistencia	34
4.5.5.	Flujo de datos completo	34
4.6.	Módulo de validación y parseo	34
4.6.1.	Diseño del validador de esquema	34
4.6.2.	Normalización del esquema de PyRIT	36
4.7.	Diseño del módulo de evaluación con IA	36
4.7.1.	Justificación de la arquitectura <i>multi-prompt</i>	36
4.7.2.	Los <i>system prompts</i> especializados	37
4.7.3.	Secuencia de llamadas y estructura del output	38
4.7.4.	Gestión de temperatura y parámetros del modelo	39
4.7.5.	Mecanismo de tolerancia a fallos en el parseo	39
4.7.6.	Gestión de reintentos en el cliente de Azure	39
4.8.	Motor de <i>scoring</i> determinista	40
4.8.1.	Justificación del enfoque determinista	40
4.8.2.	<i>Score</i> de riesgo compuesto	40
4.8.3.	<i>Score</i> de madurez de <i>hardening</i>	41
4.8.4.	ROI de seguridad de cada recomendación	41
4.8.5.	Proyección por fases con rendimientos decrecientes	42

4.9.	Catálogo de controles de referencia	42
4.9.1.	Selección de <i>frameworks</i>	42
4.9.2.	Estructura del catálogo	43
4.10.	Del análisis ofensivo al diseño de la herramienta	44
5.	Implementación	46
5.1.	Generación de informes	46
5.1.1.	Decisión de tres formatos	46
5.1.2.	Estructura del informe <i>Markdown</i>	46
5.2.	Sistema de auditoría y análisis de tendencia	47
5.2.1.	Diseño del <i>log</i> de auditoría	47
5.2.2.	Informe de tendencia multi-ejecución	48
5.2.3.	<i>Script</i> de demostración	48
5.3.	Integración con PyRIT	50
5.3.1.	Modalidades de integración	50
5.3.2.	Compatibilidad con versiones de PyRIT	50
5.3.3.	Compatibilidad con PyRIT 0.12	50
5.4.	Proceso de desarrollo y testing	51
5.4.1.	Metodología de desarrollo	51
5.4.2.	Decisión de no utilizar <i>pytest</i>	51
5.4.3.	Uso de <i>mocks</i> para Azure OpenAI	52
5.4.4.	Cobertura de la <i>suite</i> de tests	52
6.	Evaluación experimental y resultados	55
6.1.	Enfoque metodológico general	55
6.2.	Reconocimiento y entorno de experimentación	56
6.2.1.	Revisión sistemática de la literatura	56
6.2.2.	Estudio del ecosistema de ataque	57
6.2.3.	Configuración del <i>testbed</i> SaaS	57
6.3.	Diseño y ejecución de la campaña ofensiva	59
6.3.1.	Diseño experimental de las campañas de ataque	59
6.3.2.	Reconocimiento manual y hallazgo del vector de <i>oversharing</i>	60
6.3.3.	Automatización con PyRIT	61
6.3.4.	Hallazgos de la campaña ofensiva	64
6.3.5.	Análisis de causas raíz: <i>oversharing</i> y herencia de permisos rota	65
6.4.	Resultados de la campaña de enumeración directa	67
6.4.1.	Volumen y tasa de éxito global	67
6.4.2.	Desglose por origen del <i>prompt</i>	68
6.4.3.	Distribución de severidad	68
6.4.4.	Volumen de exfiltración y concentración del <i>oversharing</i>	68
6.4.5.	Análisis cuantitativo de causas raíz	69
6.4.6.	Nota sobre el enfoque descartado (Anecdactor)	69

6.5.	Resultados del análisis y bastionado con GAIHF	70
6.5.1.	<i>Score</i> de riesgo compuesto	70
6.5.2.	Recomendaciones de <i>hardening</i> generadas	71
6.5.3.	Proyección de reducción de riesgo por fases	71
6.5.4.	Ejemplo de informe generado	72
6.6.	Discusión de los resultados	72
6.6.1.	Amenazas a la validez	72
6.7.	Síntesis del capítulo	73
7.	Conclusiones y trabajos futuros	74
7.1.	Conclusiones generales	74
7.2.	Grado de consecución de los objetivos	75
7.3.	Contribuciones principales	76
7.4.	Limitaciones	76
7.5.	Trabajos futuros	77
7.6.	Consideraciones éticas y legales	78
7.7.	Reflexión final	78

Índice de figuras

2.1.	Diagrama de Gantt del proyecto. En gris aparecen las actividades que salieron según lo planificado y, con trama diagonal, las que acabaron desplazándose respecto al plan inicial. Los rombos negros marcan los hitos principales, y la barra punteada de abajo corresponde a la redacción de la memoria, que va en paralelo a todo lo demás.	14
4.1.	Representación general del sistema	29
4.2.	Diagrama de secuencia: Ataque de AI <i>Red Teaming</i>	31
4.3.	Arquitectura de GAIHF, repartida en cuatro capas de procesamiento. Las capas se comunican entre sí pasándose diccionarios <i>Python</i> con un esquema normalizado.	33
4.4.	Recorrido completo de los datos en GAIHF, desde que entra el JSON de <i>PyRIT</i> hasta que se generan los informes y se registra la auditoría.	35
4.5.	Diagrama de secuencia con las cuatro llamadas que se hacen a <i>Azure OpenAI</i> : análisis ejecutivo, evaluación técnica, <i>hardening</i> de <i>Microsoft 365</i> y plan de acción.	38
4.6.	Proyección <i>ilustrativa</i> de cómo iría bajando el <i>score</i> de riesgo de <i>Microsoft 365</i> a lo largo de las distintas fases, calculada por el motor de <i>scoring</i> de GAIHF (determinista, aunque apoyado en parámetros heurísticos) sobre los resultados de la campaña de 150 <i>prompts</i> . La línea discontinua señala dónde empieza la banda MEDIO: el <i>score</i> arranca en torno a 5,6 (MEDIO) y, una vez completado el plan, se queda del orden de 0,2 (BAJO). Son valores orientativos, no una medida real de <i>antes/después</i>	43
5.1.	Informe HTML que genera GAIHF. Las tarjetas de arriba recogen las métricas clave y, en la tabla de recomendaciones, cada nivel de prioridad tiene su propio color.	47

5.2.	Ejemplo de informe de tendencia en HTML generado con <code>trend_reporter.py</code> , donde se ve cómo evoluciona el score de PyRIT a lo largo de cuatro rondas de <i>red teaming</i> aplicando <i>hardening</i> entre unas y otras. Los datos salen de la simulación del script <code>demo_trend.py</code>	49
5.3.	Salida del <i>runner</i> de tests <code>run_tests.py</code> mostrando los resultados de las 10 <i>suites</i> y el resultado final de 209/209 tests pasados.	54
6.1.	Visión general del enfoque y del ciclo de realimentación <i>Red Team / Blue Team</i> entre la evaluación ofensiva y el diseño de las recomendaciones.	56
6.2.	Arquitectura del motor de ataque automatizado basado en PyRIT 0.12. El componente sombreado (<code>CopilotChatTarget</code>) es una extensión original desarrollada para este trabajo; el resto son componentes nativos de la librería.	62
6.3.	Tasa de éxito de exfiltración, entendida como el porcentaje de <i>prompts</i> que consiguen al menos un fichero del <i>tenant</i> , según de dónde salió cada <i>prompt</i> : semillas revisadas a mano ($n = 27$), <i>prompts</i> generados de forma automática por el modelo <i>few-shot</i> ($n = 123$) y el conjunto entero ($n = 150$). Que la generación automática aguante una tasa de éxito tan alta es lo que acredita el enfoque de crear <i>prompts</i> nuevos. Datos de la campaña definitiva (150 <i>prompts</i>).	66
6.4.	Distribución de las causas raíz detrás de los accesos exitosos. A cada activo al que se llegó se le asigna una causa con una regla reproducible sobre las evidencias de <i>grounding</i> : si el nombre del fichero es a todas luces sensible, se apunta a la ausencia de etiquetas de sensibilidad; si es un documento ofimático en un sitio de <code>SharePoint</code> , a la herencia de permisos no auditada; y todo lo demás (páginas y listados, <code>OneDrive</code> , web) cae en el alcance de búsqueda sin restringir. Esta atribución es una aproximación práctica, porque las causas no se excluyen entre sí. La curva acumulada deja ver el principio de Pareto: unas pocas deficiencias de gobernanza son las que explican la mayor parte de los accesos. Datos de la campaña definitiva (46 activos únicos).	67
6.5.	Distribución de la severidad de las exfiltraciones exitosas (escala de privacidad 0–10) sobre los 128 ataques con éxito de la campaña de 150 <i>prompts</i>	69

6.6. Sitios del <i>tenant</i> con mayor número de citas de <i>grounding</i> en los ataques exitosos (medida de concentración del <i>oversharing</i>). Los nombres de los sitios se han anonimizado (“Sitio A”, “Sitio B” . . . ; “OneDrive-A” para unidades personales) por motivos de confidencialidad; se conservan el número de accesos y el tipo de recurso. Un número reducido de sitios concentra la mayor parte de los accesos. Datos de la campaña definitiva (46 activos únicos).	70
--	----

Índice de tablas

2.1.	Matriz detallada de requisitos funcionales.	8
2.2.	Análisis de riesgos operativos del sistema.	10
2.3.	Distribución de horas por fase y actividad principal.	10
2.4.	Herramientas y plataformas utilizadas durante el proyecto. . .	14
2.5.	Presupuesto estimado del proyecto (tarifas de julio de 2026). .	16
4.1.	Correspondencia entre score PyRIT y banda de riesgo.	37
4.2.	Pesos heurísticos asignados a cada categoría de daño para el cálculo del score de riesgo compuesto. Son valores orientativos, fijados por criterio experto y no calibrados empíricamente. . .	41
4.3.	Reducción de riesgo y esfuerzo estimados por nivel de priori- dad. Se trata de constantes heurísticas (derivadas de CVSS y de informes de incidentes), no de valores medidos; determinan las proyecciones del motor de <i>scoring</i> y deben interpretarse como orientativas.	42
4.4.	Distribución de controles de referencia por categoría de daño y <i>framework</i>	44
5.1.	Cobertura de la suite de tests de GAIHF (209 tests totales). .	53
6.1.	Volumen y resultado global de la campaña de enumeración directa (150 <i>prompts</i>).	68
6.2.	Proyección ilustrativa de cómo baja el <i>score</i> de riesgo fase a fase (cálculo determinista de GAIHF a partir de parámetros heurísticos; son valores orientativos, no medidos).	71

Capítulo 1

Motivación

1.1. Contexto

En poco tiempo la inteligencia artificial ha pasado de ser una promesa a estar presente en el día a día de muchas organizaciones. Dentro de ese movimiento, los grandes modelos de lenguaje (LLM) son probablemente el caso más visible: en apenas unos años han dejado de ser simples generadores de texto para convertirse en el núcleo de arquitecturas agénticas, capaces de razonar sobre una tarea, encadenar pasos y, sobre todo, ejecutar acciones reales sobre sistemas y recursos externos.

Buena parte de ese salto se explica por dos ingredientes que se han vuelto habituales. Por un lado, la generación aumentada por recuperación (RAG) [1], que permite al modelo apoyar sus respuestas en documentos y datos de la propia organización en lugar de limitarse a lo que aprendió durante el entrenamiento. Por otro, las interfaces de programación de aplicaciones (API) y las llamadas a herramientas, que le dan al modelo un brazo ejecutor para interactuar con otros servicios. El problema es que esa misma capacidad que lo hace útil es la que amplía su superficie de ataque: cada nueva conexión con datos o con herramientas es también una vía que un adversario puede intentar aprovechar.

Este cambio se nota especialmente en el ámbito empresarial. Una parte enorme del tejido corporativo trabaja hoy en día sobre *suites* de productividad en la nube como **Microsoft 365**, que ya no se limitan a ofrecer correo y ofimática, sino que incorporan sus propios asistentes de IA generativa como **Microsoft 365 Copilot** [2]. Lo relevante aquí es que esos asistentes no operan aislados: se apoyan en el resto de servicios de la *suite* (**SharePoint**, **OneDrive**, **Exchange**, **Teams**) y utilizan la información que allí reside como material de partida (*grounding*) para construir sus respuestas.

Y aquí está el matiz que motiva este trabajo. El asistente actúa bajo la

identidad del propio usuario, de modo que hereda todo lo que ese usuario puede leer. Dicho de otra forma, deja de importar únicamente qué permisos tiene una persona sobre un fichero concreto y pasa a importar qué es capaz de sacar a la luz una simple conversación en lenguaje natural. Si un adversario consigue llegar solo a la aplicación de IA de la *suite*, no se queda ahí: obtiene una vía de acceso efectiva a un conjunto muy amplio de recursos de la organización, sin necesidad de vulnerar cada servicio por separado.

Este trabajo se sitúa justo en ese punto, en el de una tecnología que se está adoptando a gran velocidad pero cuyas implicaciones de seguridad todavía se entienden y se controlan a medias.

1.2. Motivación del estudio

La motivación de este trabajo parte de una contradicción que se repite en muchas organizaciones. Se despliega **Copilot** con la idea de ganar productividad, algo perfectamente razonable, pero al hacerlo la superficie de ataque crece por un lado para el que los controles de seguridad habituales no estaban pensados. Durante años la defensa se ha construido alrededor de la red y del *endpoint*; ahora, sin embargo, el perímetro incluye también el lenguaje natural, que es precisamente por donde se conversa con el asistente. Y esa es una frontera mucho más difícil de vigilar con las herramientas de siempre.

El origen del riesgo tiene que ver con cómo funciona el asistente. A diferencia del software convencional, **Copilot** no tiene una cuenta de servicio con permisos acotados, sino que trabaja con la identidad delegada del usuario [3]. Esto significa que puede leer cualquier cosa que ese usuario pueda leer y, en la práctica, esos permisos suelen estar peor gobernados de lo que se cree: carpetas compartidas de más, herencias mal configuradas, documentos que fueron accesibles a todo el mundo por comodidad y nunca se revisaron, etc. Es lo que se conoce como *oversharing* o compartición excesiva de datos. El resultado es que información sensible que en teoría estaba «escondida», por el simple hecho de que nadie la buscaba, pasa a estar a un mensaje de distancia: basta con pedirselo al asistente en lenguaje natural para que la localice, la resuma y la sirva, sin que llegue a producirse ninguna intrusión en el sentido clásico [4].

A esta situación se suma que el campo todavía es inmaduro a la hora de medir y asegurar este tipo de sistemas. No es una impresión personal: el propio NIST señaló esta carencia en su perfil de IA Generativa de julio de 2024 [5], y el marco regulatorio que ya está en vigor, con el Reglamento Europeo de IA a la cabeza [6], empuja a las empresas a demostrar que gestionan estos riesgos de forma seria. El problema es que hay una distancia grande entre lo

que la normativa exige y las herramientas concretas de las que dispone un equipo de seguridad para evaluar un despliegue de IA real.

Reducir esa distancia a mano no es viable. El ritmo al que se activan estos asistentes en las organizaciones hace que auditar cada configuración de permisos de forma manual sea, sencillamente, inabarcable. Por eso tiene sentido apoyarse en metodologías de *AI Red Teaming* automatizadas, que permiten emular el comportamiento de un adversario de manera proactiva, antes de que sea un atacante real quien encuentre el hueco. Ahora bien, emular al adversario solo resuelve la mitad del problema: una campaña ofensiva genera una montaña de resultados en bruto, pero no dice por sí misma qué hay que tocar ni cómo. Esa carencia, la de traducir los hallazgos en acciones de bastionado concretas y sobre una gobernanza sólida de identidades y permisos, es exactamente la que este trabajo pretende atacar.

Conviene advertir desde el inicio una restricción que condiciona la presentación de los resultados: las pruebas se realizaron sobre un *tenant* corporativo real con información confidencial. Por ese motivo, y en cumplimiento de las *Rules of Engagement* acordadas, los resultados que se muestran en el Capítulo 6 están anonimizados y se acompañan de un número deliberadamente reducido de capturas de pantalla. Las capturas incluidas corresponden al modo demo de la herramienta (con datos simulados), nunca a información real del *tenant*.

1.3. Objetivos

1.3.1. Objetivo general

El objetivo principal de este proyecto es diseñar y desarrollar una metodología automatizada para el bastionado de cuentas y proyectos de IA generativa en entornos SaaS corporativos, apoyada en una herramienta de software original que transforme los hallazgos de ataques adversariales en recomendaciones técnicas de endurecimiento precisas.

1.3.2. Objetivos específicos

Para alcanzar el objetivo general, se proponen los siguientes hitos:

1. Analizar el estado del arte de la ciberseguridad en GenAI, fundamentando la investigación en los marcos *MITRE ATLAS* y *OWASP 2025* [7], [8].
2. Configurar un *testbed* SaaS que reproduzca escenarios corporativos reales para evaluar vulnerabilidades de *oversharing*.

3. Implementar un motor de ataque automatizado utilizando PyRIT, requiriendo un entorno de ejecución basado en Python 3.10 o superior para garantizar la compatibilidad con orquestadores multi-turno [9].
4. Desarrollar una herramienta de interpretación basada en IA que procese los *logs* y *scores* de PyRIT para identificar causas raíz de fallos de seguridad [9].
5. Mapear las vulnerabilidades detectadas con controles de seguridad específicos (DLP, etiquetas de sensibilidad) en entornos Microsoft [3].
6. Validar la metodología cuantificando, mediante el motor de *scoring* determinista de la herramienta, la reducción de riesgo esperable tras aplicar las recomendaciones de bastionado. Cerrar el ciclo *Red Team vs. Blue Team* de forma empírica, es decir, aplicar el *hardening* sobre el *tenant* y volver a lanzar los ataques para ver cuánto baja su tasa de éxito, queda planteado como la principal línea de trabajo futuro.

1.4. Organización de la memoria

El resto del documento sigue el mismo orden en que se abordó el trabajo, de manera que cada capítulo se apoya en el anterior. Este primer capítulo ha servido para situar el problema: el contexto en el que aparece, por qué merece la pena estudiarlo, hasta dónde llega el alcance del trabajo y qué objetivos se persiguen.

El Capítulo 2 recoge la planificación del proyecto: el alcance del trabajo, la especificación de requisitos, el análisis de recursos y de riesgos, la temporización del desarrollo y el presupuesto económico.

A continuación, el Capítulo 3 revisa el estado del arte. Recorre la evolución de los LLM hacia las arquitecturas agénticas y, sobre esa base, presenta los marcos de referencia en seguridad de IA y la taxonomía de amenazas pertinentes, cerrando con las limitaciones actuales que motivan la propuesta.

El Capítulo 4 concentra la contribución principal en su vertiente de diseño: presenta GAIHF, la herramienta de recomendación, con su arquitectura en cuatro capas, el módulo de análisis con IA, el motor de *scoring* determinista y el catálogo de controles de referencia.

El Capítulo 5 baja al detalle de la implementación: las herramientas con las que se pone en marcha la propuesta, la integración con PyRIT, la generación de informes y el proceso de desarrollo y *testing*.

El Capítulo 6 constituye la evaluación experimental. Describe primero la metodología ofensiva y el entorno de experimentación (la enumeración directa por *oversharing* contra Microsoft 365 Copilot orquestada con PyRIT, el

testbed y la métrica de éxito basada en *grounding*) y presenta después los resultados cuantitativos de la campaña y del bastionado que produce GAIHF, junto con su discusión crítica.

Por último, el Capítulo 7 cierra la memoria con las conclusiones, valora en qué medida se cumplieron los objetivos, resume las aportaciones del trabajo y expone tanto sus limitaciones como las líneas que quedan abiertas para el futuro.

Capítulo 2

Planificación

2.1. Alcance del estudio

El presente Trabajo de Fin de Grado se circunscribe al bastionado (*hardening*) de cuentas y proyectos dentro del entorno SaaS de **Microsoft 365**. El estudio comprende:

- La investigación de tácticas ofensivas documentadas en la matriz **MITRE ATLAS**, que ha evolucionado hasta incluir 84 técnicas en 16 categorías tácticas en su actualización de 2025 [7].
- El análisis de los riesgos tipificados en el **OWASP Top 10 para Aplicaciones LLM (Edición 2025)**, con especial énfasis en la inyección de *prompts* y la agencia excesiva [8].
- El despliegue de una infraestructura de ataque basada en **PyRIT** (*Python Risk Identification Tool*), herramienta de referencia utilizada por el *Microsoft AI Red Team* [9].
- El desarrollo y validación de una herramienta original para la interpretación de resultados y la generación de recomendaciones técnicas de remediación en **Microsoft Purview** y el centro de administración de **Microsoft 365**.

2.2. Requisitos técnicos del entorno

Para garantizar la reproducibilidad de las pruebas, se han establecido requisitos técnicos rigurosos.

2.2.1. Requisitos de software y dependencias

El sistema requiere un entorno controlado basado en contenedores o entornos virtuales de Python para evitar conflictos de librerías.

- **Versión de Python:** 3.10.x o superior.
- **Framework ofensivo:** se trabaja sobre PyRIT 0.12, aunque el código sigue siendo compatible con versiones anteriores.
- **Motor de análisis:** Azure OpenAI, al que se accede con el SDK oficial `openai`. No hace falta añadir ninguna capa de orquestación por encima.
- **Gestión de secretos:** las credenciales se pasan por variables de entorno con ayuda de `python-dotenv` y se dejan fuera del control de versiones.

2.2.2. Configuración del *tenant* de pruebas

Es imperativo que el sistema no se ejecute sobre un *tenant* de producción sin autorización y supervisión explícitas. En este trabajo, las pruebas se realizaron sobre un *tenant* desplegado a modo de gemelo digital cedido por Innovasur como de entorno de laboratorio, bajo unas *Rules of Engagement* acordadas (véase el Capítulo 6):

- **Licenciamiento:** Microsoft 365 E5, para disponer de las API de seguridad avanzadas.
- **Contenido real:** el contenido no son datos reales pero sí realistas para conseguir unos resultados los más próximos posibles a los que se conseguirían realizando las pruebas en un *tenant* en producción.

2.3. Especificación de requisitos funcionales y no funcionales

Esta sección detalla las capacidades mínimas que el sistema debe cumplir para ser considerado operativo en un entorno corporativo.

2.3.1. Requisitos funcionales (RF)

2.3.2. Requisitos no funcionales (RNF)

- **RNF-01 — Control de cuota y robustez:** el ritmo de envío de *prompts* se limita de forma deliberada (espaciado entre peticiones y

ID	Nombre	Descripción detallada
RF-01	Entrada y validación	Aceptar los resultados en formato PyRIT (JSON) y validar su estructura antes de procesarlos, agrupándolos por categoría de daño; en este trabajo, la exfiltración por <i>oversharing</i> .
RF-02	Independencia del atacante	Consumir esos resultados sea cual sea la herramienta que los generó; el objetivo evaluado es Microsoft 365 Copilot.
RF-03	Métrica determinista	Determinar el éxito a partir de las citas de <i>grounding</i> y estimar la severidad con un <i>scorer Likert</i> de privacidad.
RF-04	Análisis de permisos	Identificar cuándo un ataque tuvo éxito por una configuración de permisos excesiva (herencia no auditada, comparticiones amplias) en SharePoint u OneDrive.
RF-05	<i>Scoring</i> reproducible	Calcular métricas deterministas: <i>score</i> de riesgo compuesto, madurez de <i>hardening</i> , proyección de reducción por fases y <i>score</i> PyRIT proyectado.
RF-06	Recomendaciones priorizadas	Generar recomendaciones de <i>hardening</i> para Microsoft 365, priorizadas por criticidad (CRÍTICA, ALTA, MEDIA, BAJA) y ordenadas por ROI, con la ruta exacta en el portal de administración y el control de referencia asociado (CIS / MITRE ATLAS / OWASP LLM).
RF-07	Generación de informes	Exportar los hallazgos en Markdown, JSON y HTML, para su integración con la documentación de seguridad y con sistemas SIEM/SOAR.
RF-08	Auditoría e historial	Registrar cada ejecución en un <i>log</i> de auditoría persistente que permita comparar rondas sucesivas de <i>red teaming</i> .
RF-09	Modos de operación	Ofrecer un modo demo sin credenciales reales y admitir tanto el uso por línea de comandos como la integración programática con <i>scripts</i> de PyRIT.

Tabla 2.1: Matriz detallada de requisitos funcionales.

tope por minuto) para respetar los límites de la API y evitar bloqueos por *rate limit* (HTTP 429), primando la completitud de la campaña sobre la velocidad.

- **RNF-02 — Determinismo del *scoring*:** ante la misma entrada, el

cálculo de *scoring* produce siempre la misma salida, con independencia del estado del modelo de lenguaje.

- **RNF-03 — Modularidad:** la arquitectura en capas permite añadir módulos, categorías de daño o controles de referencia sin afectar al resto del sistema.
- **RNF-04 — Dependencias mínimas:** las únicas dependencias externas son `openai` y `python-dotenv`; el resto se apoya en la biblioteca estándar de Python 3.10.
- **RNF-05 — Seguridad de la información:** las credenciales y los ficheros sensibles (`.env`, *logs* de auditoría e informes) quedan fuera del control de versiones, y la métrica de éxito registra solo la referencia a los ficheros del *tenant*, nunca su contenido.
- **RNF-06 — Verificabilidad:** la suite de *tests* cubre todos los módulos y se ejecuta sin credenciales de **Azure OpenAI** mediante objetos *mock*.
- **RNF-07 — Errores accionables:** ante un JSON de PyRIT inválido, el sistema devuelve mensajes de error descriptivos en lugar de excepciones crípticas.
- **RNF-08 — Coste y latencia:** el uso de LLMs se optimiza con modelos pequeños (por ejemplo, `gpt-5-mini`) y el análisis completo se mantiene por debajo de cinco minutos en condiciones normales de latencia.

2.4. Análisis de riesgos de la implementación

La ejecución de un *framework* de ataque, incluso con fines defensivos, conlleva riesgos intrínsecos que deben ser mitigados. Véase la Tabla 2.2.

2.5. Planificación temporal y estimación de esfuerzo

2.5.1. Parámetros generales de la planificación

La estimación de esfuerzo se ajusta a la carga de trabajo prevista para un Trabajo de Fin de Grado de 12 créditos ECTS, a razón de unas 30 horas por crédito, lo que supone en torno a 360 horas de trabajo efectivo del autor. Estas horas se distribuyeron a lo largo de los 9 meses del proyecto (de octubre de 2025 a junio de 2026), con una dedicación variable según la fase. A ellas

Riesgo	Impacto	Probabilidad	Mitigación
Envenenamiento de logs de auditoría	Alto	Media	Uso de prefijos específicos en los ataques para facilitar el filtrado posterior.
Consumo excesivo de cuota de API	Medio	Alta	Implementación de límites de gasto y alertas en tiempo real.
Falsos positivos en recomendaciones	Bajo	Media	Validación humana obligatoria antes de aplicar cambios de política.
Exposición de vulnerabilidades reales	Crítico	Baja	Almacenamiento de informes en entornos desconectados (Air-gapped).

Tabla 2.2: Análisis de riesgos operativos del sistema.

hay que sumar las horas de supervisión de la dirección, que se contabilizan por separado en el presupuesto (Sección 2.5.6).

El desarrollo se organizó en tres fases: la **Fase I** (reconocimiento y configuración del entorno), la **Fase II** (evaluación adversarial ofensiva) y la **Fase III** (síntesis y desarrollo de la herramienta GAIHF). El reparto de horas entre ellas deja ver el peso de cada una dentro de la metodología: la Fase II se lleva ella sola en torno al 42 % del esfuerzo, algo que encaja con sus cinco meses de duración y con lo iterativas que fueron las campañas de ataque. En la Tabla 2.3 está el desglose por fase y actividad principal.

Tabla 2.3: Distribución de horas por fase y actividad principal.

Fase	Actividad principal	Meses	Horas
Fase I	Revisión sistemática de la literatura	1–2	50
	Análisis del ecosistema de ataque	1–2	20
	Configuración del <i>testbed</i>	2	20
Fase II	Ingeniería manual de <i>prompts</i>	3–4	40
	Desarrollo de <i>converters/scorers</i>	4–5	30
	Campañas automatizadas con PyRIT	5–7	55
	Análisis de hallazgos	6–7	25
Fase III	Diseño de la arquitectura de la herramienta	8	20
	Desarrollo de GAIHF	8–9	50
	<i>Testing</i> y validación	9	20
	Redacción de la memoria	1–9	30
Total		9	360

Nota: la estimación de 360 h corresponde a la dedicación del autor, acorde

con los 12 créditos ECTS del TFG. Dentro de ese total, las campañas de la Fase II concentran el mayor esfuerzo por su carácter iterativo, sobre todo al incorporar la estrategia `MultiPromptSendingAttack` de `PyRIT 0.12`. Las horas de supervisión de la dirección se contabilizan aparte en el presupuesto (Sección 2.5.6).

2.5.2. Desglose mensual de actividades

A continuación se describe el desglose detallado de actividades por mes, incluyendo los hitos principales y los bloqueos identificados.

Meses 1–2: Revisión bibliográfica y espera de credenciales

Los dos primeros meses se fueron enteros en asentar la base teórica del trabajo. La revisión de la literatura terminó llevando más tiempo del que se había calculado, en buena parte porque en la segunda mitad de 2025 no paraban de salir publicaciones sobre seguridad de LLM (el `NIST AI RMF` en julio de 2025 o el `OWASP Top 10 for Agentic Applications 2026`, por ejemplo), que traían marcos de referencia importantes justo cuando el proyecto ya estaba en marcha.

Un **bloqueo** significativo fue la demora en la recepción de las credenciales del tenant de pruebas. Las credenciales del usuario del tenant `Microsoft 365 E5` proporcionado por Innovasur no estuvieron disponibles hasta el inicio de la semana 7, cuando estaban previstas para la semana 4. Esta demora, motivada por procesos internos de aprovisionamiento, redujo el tiempo disponible para la configuración del *testbed* en el Mes 2 y desplazó el inicio de la Fase II una semana respecto a la planificación original. Como acción correctiva, el tiempo de espera se aprovechó para avanzar en el diseño conceptual de los escenarios de ataque y en el desarrollo de los primeros borradores de *prompts* maliciosos, actividad que en la planificación original estaba prevista para el Mes 3.

Los hitos completados al final del Mes 2 fueron:

- Revisión sistemática de la literatura completada (30 referencias incluidas en la bibliografía final).
- Marcos de referencia seleccionados y documentados (`NIST AI RMF`, `OWASP LLM 2025`, `MITRE ATLAS`).
- *Tenant* de pruebas aprovisionado y acceso autorizado a su contenido corporativo real bajo las *Rules of Engagement*.
- Catálogo preliminar de semillas de enumeración diseñado y organizado por categoría de dato objetivo.

Meses 3–4: Fase ofensiva manual

Los Meses 3 y 4 se dedicaron al reconocimiento manual descrito en la Sección 6.3.2: la interacción directa con Copilot para caracterizar qué peticiones conducen realmente a la exfiltración. Esta etapa fue fundamental para descubrir el vector de *oversharing* y para construir el conjunto de *prompts* semilla que alimenta la automatización.

El principal desafío técnico de este período fue la comprensión del modelo de autenticación delegada de Microsoft Graph API y su impacto en la superficie de ataque de Copilot. La API de Microsoft Graph permite a Copilot acceder, en nombre del usuario, a todos los recursos para los que este tiene permisos, incluyendo SharePoint, Outlook, Teams y OneDrive, sin requerir consentimiento explícito del usuario en cada solicitud. Esta arquitectura es la base del *oversharing*: un usuario con permisos excesivos en SharePoint transfiere implícitamente esos permisos a Copilot.

Los hitos completados al final del Mes 4 fueron:

- Reconocimiento manual completado y vector de *oversharing* confirmado sobre el *tenant*.
- Conjunto de 27 *prompts* semilla verificados y organizados por categoría de dato objetivo.
- Métrica de exfiltración determinista definida (recuento de ficheros del *tenant* citados en las atribuciones de la respuesta de Copilot).
- Documentación de los tres patrones de causa raíz identificados en los ataques exitosos.

Meses 5–7: Automatización con PyRIT

Los meses centrales del proyecto se dedicaron a la automatización de la campaña de enumeración directa (`pyrit_direct_exfil.py`) y al análisis de los resultados. La integración con PyRIT 0.12 presentó algunas dificultades técnicas menores relacionadas con el cambio de repositorio (de Azure/PyRIT a microsoft/PyRIT) y con el *backend* de memoria SQLite, que requirieron adaptar los scripts de exportación de resultados.

El principal reto operativo de este período fue el *throttling* (HTTP 429) que impone la *Chat API* de Copilot sobre las campañas de gran volumen, que obligó a introducir reintentos con *backoff*, espaciado entre envíos y *check-point* por *prompt*. Tanto la generación automática de *prompts* nuevos como el *scoring* de severidad se apoyaron en el modelo auxiliar `gpt-5-mini` de Azure OpenAI, cuyo consumo se controló con un límite de peticiones por minuto para evitar su propio *throttling*.

Los hitos completados al final del Mes 7 fueron:

- Campaña automatizada operativa: 27 semillas ampliadas mediante generación *few-shot* hasta 150 *prompts*.
- Tasa de éxito de exfiltración observada del 85,3 % (128/150); *score* de riesgo base en torno a 5,6/10.
- Análisis de causa raíz completado sobre los ataques exitosos.
- Mapeado preliminar de hallazgos a controles CIS/ATLAS/OWASP.
- Especificación de requisitos de GAIHF completada.

Meses 8–9: Desarrollo de la herramienta

Los dos últimos meses se dedicaron íntegramente al diseño, desarrollo, *testing* y validación de GAIHF, actividades descritas en detalle en los Capítulos 5 y 6, así como a la consolidación de los resultados de la campaña y a la generación de los informes de *hardening*.

Los hitos completados al final del Mes 9 fueron:

- GAIHF v1.0 completada y validada (209 tests, 100 % de cobertura de módulos críticos).
- Informes de *hardening* generados; GAIHF proyecta, de forma determinista pero con parámetros heurísticos, una reducción orientativa del *score* de riesgo desde el nivel base (en torno a 5,6/10) hasta un nivel bajo (del orden de 0,2/10).
- Memoria del TFG completada.

2.5.3. Diagrama de Gantt

La Figura 2.1 presenta el diagrama de Gantt del proyecto, mostrando la distribución temporal de las actividades principales, los hitos clave y las relaciones de dependencia entre tareas. Las actividades de redacción de la memoria se representan como una tarea transversal de baja intensidad que recorre todo el horizonte temporal del proyecto.

2.5.4. Herramientas y entorno de trabajo

El desarrollo y la ejecución del proyecto requirieron la configuración de un entorno de trabajo consistente y reproducible. La Tabla 2.4 resume las herramientas y plataformas utilizadas a lo largo del proyecto.




Figura 2.1: Diagrama de Gantt del proyecto. En gris aparecen las actividades que salieron según lo planificado y, con trama diagonal, las que acabaron desplazándose respecto al plan inicial. Los rombos negros marcan los hitos principales, y la barra punteada de abajo corresponde a la redacción de la memoria, que va en paralelo a todo lo demás.

Tabla 2.4: Herramientas y plataformas utilizadas durante el proyecto.

Categoría	Herramienta / Plataforma	Uso principal
Tenant SaaS	Microsoft 365 E5 Developer	<i>Target</i> de ataques
Emulación adversarial	PyRIT 0.12.0	Motor de ataque
Modelo auxiliar (LLM)	Azure OpenAI gpt-5-mini	Generación de <i>prompts</i> y <i>scoring</i>
Modelo objetivo	Microsoft 365 Copilot	<i>Target</i> conversacional
Entorno Python	Python 3.11.x (venv)	Desarrollo y scripts
Base de datos	SQLite 3.x	Almacenamiento de sesiones
Recomendaciones	Azure OpenAI gpt-5-mini	Motor de análisis de GAIHF
Versionado	Git / GitHub	Control de versiones
Documentación	L ^A T _E X (pdflatex)	Memoria del TFG
Diagramas	draw.io	Figuras técnicas

2.5.5. Consideraciones sobre la reproducibilidad

Uno de los principios metodológicos transversales del proyecto fue garantizar la **reproducibilidad** de los experimentos. Este principio se operacionalizó en tres niveles:

- **Nivel de entorno:** todas las dependencias Python se especificaron con versiones fijas en el fichero `requirements.txt` y el *tenant* de pruebas se documentó con una guía de configuración paso a paso.
- **Nivel de datos y campaña:** al operar sobre el contenido real de un *tenant* corporativo, el conjunto exacto de datos no es replicable por terceros. Como contrapartida, se documentan las 27 semillas verificadas y los parámetros de la campaña. Hay que tener en cuenta que la generación automática de *prompts* utiliza temperatura alta, de modo que el conjunto concreto de peticiones varía entre ejecuciones; la reproducibilidad estricta queda garantizada, por tanto, a nivel de la métrica de éxito y del *scoring* (nivel de resultados), no del corpus.
- **Nivel de resultados:** los *scores* de las campañas de ataque se almacenaron en la base de datos `SQLite` de `PyRIT` con la marca temporal y los parámetros exactos de cada ejecución. El motor de *scoring* determinista de `GAIHF` asegura que las métricas derivadas son idempotentes: dado el mismo `JSON` de `PyRIT`, la herramienta produce siempre el mismo resultado, con independencia del estado del modelo de lenguaje [9].

2.5.6. Análisis de coste económico

El proyecto se desarrolló sobre recursos cedidos, un *tenant* `Microsoft 365 E5 Developer` sin coste y equipamiento propio, por lo que el desembolso real fue reducido. No obstante, a efectos de planificación conviene estimar el coste que tendría reproducir el trabajo en un entorno realista. La Tabla 2.5 recoge ese presupuesto, desglosado en recursos humanos, hardware y software/servicios en la nube. Los precios de hardware y software corresponden a tarifas de lista vigentes en julio de 2026; se aplica una conversión aproximada de 1 USD $\approx$ 0,92 €, teniendo en cuenta que los precios de lista en euros pueden variar y que incluyen el 21 % de IVA en España.

Recursos humanos. La dedicación del autor se estima en 360 h (Sección 2.5.1) a 30 €/h, tarifa habitual de un ingeniero *junior*. Se añaden unas 40 h de supervisión conjunta de la dirección (reuniones periódicas y revisión de la memoria y del código) a una tarifa media de 95 €/h.

Hardware. El trabajo no exige cómputo intensivo, la carga real recae en las API en la nube, pero sí una estación de trabajo solvente para el

desarrollo, la ejecución de PyRIT y las pruebas de modelos locales planteadas como línea futura. Se toma como referencia un portátil Lenovo ThinkPad P1 Gen 8 (Intel Core Ultra 7 255H, 32 GB de RAM, 1 TB SSD y GPU NVIDIA RTX Pro 2000), con un precio de lista de unos 3.525 USD ($\approx$ 3.245 €). Amortizado en una vida útil de 4 años, la parte imputable a los 9 meses del proyecto es de unos 610 €.

Software y servicios en la nube. La cadena de desarrollo (PyRIT, Python, L^AT_EX/MiKTeX, Visual Studio Code, Git/GitHub y draw.io) es gratuita o de código abierto. Los costes provienen de las licencias de Microsoft (Microsoft 365 E5 a 60 USD por usuario y mes y el complemento Microsoft 365 Copilot a 30 USD por usuario y mes) y del consumo de Azure OpenAI. Para el modelo auxiliar gpt-5-mini (0,125 USD por millón de *tokens* de entrada y 1,00 USD por millón de salida), el gasto de todo el proyecto —del orden de 20 millones de *tokens*— no llega a 10 €. La configuración de referencia considera 5 licencias E5 y 1 licencia Copilot durante los 6 meses de uso activo del *tenant*.

Tabla 2.5: Presupuesto estimado del proyecto (tarifas de julio de 2026).

Concepto	Cantidad × precio	Coste (€)
<i>Recursos humanos</i>		
Ingeniero (autor)	360 h × 30 €/h	10.800
Supervisión (dirección)	40 h × 95 €/h	3.800
<i>Hardware</i>		
Lenovo ThinkPad P1 Gen 8 (adquisición)	1 × 3.245 €	3.245
imputación amortizada (9/48 meses)		610
<i>Software y servicios en la nube</i>		
Microsoft 365 E5	5 usu. × 6 m. × 55 €	1.656
Microsoft 365 Copilot	1 usu. × 6 m. × 28 €	166
Azure OpenAI (gpt-5-mini, $\approx$ 20 M <i>tokens</i>)	—	9
Herramientas <i>open source</i>	—	0
Total (con adquisición de hardware)		19.676
Total (con hardware amortizado)		15.041

En cualquiera de los dos escenarios, el coste está dominado por los recursos humanos; la infraestructura tecnológica, al apoyarse en servicios en la nube de pago por uso y en herramientas de código abierto, tiene un peso comparativamente reducido.

Capítulo 3

Estado del arte

3.1. Contexto actual y evolución de los LLM hacia arquitecturas agénticas

La integración de los modelos de lenguaje de gran escala (*Large Language Models*, LLM) en sistemas de producción ha crecido con enorme rapidez en los últimos años, y hoy alcanza dominios muy diversos: sanidad, ingeniería de software, finanzas corporativas o administración pública [10]. Esta adopción acelerada ha ampliado de forma significativa la superficie de exposición de los sistemas que los integran, introduciendo nuevos vectores de ataque y riesgos operacionales que van desde la manipulación adversaria del modelo hasta el envenenamiento de los datos de entrenamiento, pasando por la inyección de instrucciones (*prompt injection*) y la pérdida de confidencialidad de datos sensibles, tal y como se recoge en análisis sistemáticos recientes de seguridad en LLM [11].

Hasta hace no mucho, interactuar con un LLM era básicamente pedirle que generara texto: dabas una entrada y recibías una salida. Con la llegada de las API y los mecanismos RAG, los modelos empezaron a actuar como intermediarios entre el usuario y sistemas de información externos, pero seguían sin poder hacer nada por sí mismos. Lo que ha cambiado el escenario de seguridad de raíz es la aparición de las arquitecturas agénticas, donde el modelo ya no solo responde, sino que llama a herramientas, toma decisiones y ejecuta acciones con efecto real sobre sistemas externos.

A nivel industrial, los datos disponibles reflejan que la mayoría de las organizaciones se encuentran aún en fases de experimentación o pilotaje. Según estimaciones recientes, aproximadamente un 62 % de las organizaciones ya experimenta con agentes inteligentes en sus entornos operativos, aunque solo un 12 % ha alcanzado implementaciones parciales a escala, y apenas un 2 % dispone de despliegues completos [11]. Este crecimiento no ha venido

acompañado de un avance equivalente en los mecanismos de control, auditoría y mitigación de riesgos, lo que abre una brecha de seguridad cada vez más seria en entornos productivos.

Desde el ámbito institucional, organismos como el *National Institute of Standards and Technology* (NIST) han insistido en la necesidad de gestionar los riesgos asociados a sistemas de IA a lo largo de todo su ciclo de vida, con especial atención a la identificación y tratamiento de comportamientos no intencionados, posibles usos indebidos y otros factores que pueden derivar en resultados indeseados en sistemas con distintos grados de autonomía [10].

Que todavía no existan metodologías estándar para poner a prueba a estos agentes en escenarios hostiles es un problema que va más allá de la empresa privada: afecta también a las infraestructuras críticas, y deja claro que aún queda mucho recorrido por delante en investigación aplicada sobre este terreno [11], [12].

3.2. Marcos de referencia y estándares en seguridad de IA

Para estructurar el análisis de amenazas en este trabajo se han seleccionado tres marcos ampliamente adoptados en la industria. El NIST AI RMF se utiliza como referencia de gobernanza general; OWASP LLM Top 10 para identificar vulnerabilidades concretas en aplicaciones que usan modelos de lenguaje; y MITRE ATLAS para mapear las tácticas y técnicas que los adversarios reales emplean contra sistemas de IA. No son intercambiables: cada uno cubre un ángulo distinto del mismo problema. [11].

3.2.1. NIST AI *Risk Management Framework*

El *NIST AI Risk Management Framework* (AI RMF) [10] es el marco institucional de referencia para identificar, analizar y mitigar riesgos en sistemas de IA a lo largo de todo su ciclo de vida. Publicado por el *National Institute of Standards and Technology*, dependiente del Departamento de Comercio de Estados Unidos, su adopción se ha ido extendiendo tanto en el sector público —en parte impulsada por la Orden Ejecutiva Federal sobre IA segura, fiable y confiable [13]— como en el ámbito empresarial internacional.

El AI RMF organiza la gestión del riesgo en torno a cuatro funciones nucleares: *Govern*, *Map*, *Measure* y *Manage*. De esas cuatro, las que más nos interesan aquí son *Measure* y *Manage*: la primera da el marco para medir cómo se comporta uno de estos sistemas cuando se le somete a condiciones adversas, y la segunda, para poner en marcha los controles que corrigen lo que falla [10]. El marco añade además una serie de dimensiones del ciclo de

vida del sistema, como la tarea y la salida (*Task and Output*), que atraviesan toda la evaluación del riesgo.

Ya en el terreno concreto de la evaluación adversaria, en julio de 2025 el NIST publicó una guía técnica, *NIST AIRETE: AI Red Teaming and Evaluation Guidance* [12], en la que fija protocolos, alcances y plantillas para llevar a cabo ejercicios de *red teaming* sobre modelos de IA. Es la primera vez que un organismo normativo de primer nivel pone por escrito una metodología de evaluación adversaria, y de cara a diseñar *benchmarks* reproducibles eso pesa mucho. Ahora bien, el AI RMF no baja al nivel de detalle técnico que haría falta para señalar vectores de ataque concretos en arquitecturas agénticas con *tool calling*. Por eso, útil como es, se queda a medias: hace de complemento estratégico, pero por sí solo no llega a cubrir lo que exige una evaluación de seguridad en la práctica [11].

3.2.2. OWASP Top 10 for LLM and *Agentic Applications*

OWASP (*Open Web Application Security Project*) mantiene dos documentos que vienen muy al caso para la seguridad de los sistemas basados en LLM: el *OWASP Top 10 for LLM Applications 2025* [8] y el *OWASP Top 10 for Agentic Applications 2026* [14]. Entre los dos cubren el catálogo de vulnerabilidades operativas que más se usa en la industria para esta clase de sistemas.

El primero recoge diez grandes categorías de riesgo. De todas ellas hay tres que cobran especial importancia en cuanto entra en juego la componente agéntica:

- **LLM01:2025 *Prompt Injection***: el modelo se manipula colando instrucciones maliciosas, ya sea en lo que escribe el usuario o en los datos externos que el agente acaba procesando.
- **LLM06:2025 *Excessive Agency***: aparece cuando al agente se le conceden más capacidades, permisos o funciones de las que la tarea realmente necesita. Cada permiso de más es superficie de ataque de más.
- **LLM07:2025 *System Prompt Leakage***: se filtran las directivas internas del sistema, que a veces esconden cosas delicadas como credenciales, configuraciones críticas o instrucciones de control.

El segundo documento, el de aplicaciones agénticas [14], lleva el análisis al terreno de lo que el agente es capaz de *hacer* y pone el foco en la categoría **ASI02: *Tool Misuse and Exploitation***, una de las vulnerabilidades más serias de este paradigma. La diferencia es de fondo: el daño ya no se queda en

generar un texto inapropiado, sino que llega a la interacción real con sistemas externos cuando el agente invoca herramientas de forma no autorizada o indebida. Es justo ese cambio de escala el que obliga a disponer de marcos de evaluación pensados a propósito para arquitecturas con *tool calling* [11], [14].

Ahora bien, por muy referenciadas que estén estas taxonomías, OWASP no llega a fijar métricas operativas medibles ni a contemplar escenarios complejos de agentes actuando en producción, y eso recorta bastante su utilidad a la hora de diseñar *benchmarks* técnicos [11].

3.2.3. MITRE ATLAS: tácticas y técnicas en sistemas de IA

MITRE ATLAS (*Adversarial Threat Landscape for Artificial-Intelligence Systems*) [7] mira las amenazas contra sistemas de IA desde un punto de vista operativo, y para ello desmenuza cada ataque en tácticas, técnicas y procedimientos (TTP) concretos. Su estructura recuerda a la de la matriz MITRE ATT&CK de la ciberseguridad de toda la vida, lo que permite emparejar los escenarios de prueba adversaria con lo que se ha observado en incidentes reales y darle así una base empírica al ejercicio de evaluación.

Para las arquitecturas agénticas, los flujos de ataque que más nos interesan se reparten en tres grupos. El primero reúne las técnicas de acceso inicial y manipulación del modelo, como *LLM Prompt Crafting* (AML.T0065) y *LLM Prompt Injection* (AML.T0051); hay incidentes documentados, entre ellos varios sobre asistentes de IA generativa en 2024 [11], que enseñan que estas técnicas funcionan fuera del laboratorio. El segundo tiene que ver con la ejecución e invocación de herramientas, con *LLM Jailbreak* (AML.T0054) y *AI Agent Tool Invocation* (AML.T0053) como ejemplos, y su viabilidad ha quedado comprobada en pruebas como *AgentFlayer* sobre *Copilot Studio* (2025). El tercero cubre el impacto operativo, que se concreta en daños hacia el exterior (*External Harms*, AML.T0048) y en acciones maliciosas sobre los sistemas que hay por debajo [7], [11].

ATLAS sirve, por tanto, para dar forma a la fase de diseño de un *benchmark* de seguridad de manera ordenada y bien apoyada en fuentes. Lo que ocurre es que su enfoque es sobre todo descriptivo y reactivo: no ofrece métricas cuantitativas ni protocolos de prueba estandarizados para el caso concreto del *tool calling* [11].

3.3. Taxonomía de amenazas en arquitecturas agénticas con LLM

El paso de los LLM a los paradigmas agénticos ha traído consigo un conjunto de vulnerabilidades propias que los marcos de evaluación pensados para los sistemas generativos clásicos no terminan de cubrir. En esta sección repasamos las amenazas más importantes, tal y como las reconocen tanto la literatura como los marcos de referencia de la industria [8], [11], [14].

3.3.1. Inyección de *prompts*: directa e indirecta

La *prompt injection* es la vulnerabilidad más documentada y también la más frecuente en los sistemas basados en LLM. Ocurre cuando alguien con malas intenciones mete instrucciones maliciosas en la entrada del modelo y consigue que este las siga, saltándose las restricciones que le marca el contexto del sistema (*system prompt*) [8], [15]. Dos factores la hacen especialmente escurridiza: que los modelos de lenguaje no son deterministas y que no existe una frontera clara entre lo que son datos y lo que son instrucciones. De ahí que sea un problema estructural, que difícilmente se mitiga del todo.

Suelen distinguirse dos variantes:

- **Inyección directa** (*Direct Prompt Injection*). Aquí el adversario escribe las instrucciones maliciosas directamente en el mensaje que le manda al modelo. Lo que busca puede ser saltarse las restricciones del sistema, sonsacarle el *system prompt* (*system prompt leakage*), hacerse pasar por el propio sistema o provocar acciones no autorizadas vía *tool calling*. Es un vector que preocupa sobre todo en interfaces conversacionales abiertas al público [8], [15].
- **Inyección indirecta** (*Indirect Prompt Injection*). En este caso el adversario ni siquiera habla con el modelo. Lo que hace es envenenar los datos externos que el agente va a procesar más adelante: correos, documentos, registros de una base de datos o resultados de búsquedas web. Esta variante es de las más peligrosas en entornos agénticos, porque el ataque puede dispararse de forma diferida, sin que el atacante tenga que estar presente cuando se produce [7], [16]. El trabajo de referencia de Greshake et al. sobre aplicaciones reales integradas con LLM enseña cómo la inyección indirecta se puede aprovechar para sacar información a través de herramientas legítimas o para forzar acciones sobre sistemas CRM y bases de datos RAG [16].

Herramientas de *red teaming* como PyRIT (*Python Risk Identification Toolkit*), de Microsoft Azure Research [9], permiten generar de forma auto-

mática muchas variantes adversarias de ambos tipos de inyección. Para ello recurren a la mutación semántica, a la ofuscación sintáctica (rotar caracteres, codificar en Base64, permutar tokens) y a transformaciones del contexto, todo pensado para despistar a las defensas que se basan en detectar patrones fijos [11].

3.3.2. Uso indebido de herramientas (*Tool Misuse*)

La categoría **ASI02: *Tool Misuse and Exploitation*** del *OWASP Top 10 for Agent Applications 2026* [14] recoge los casos en los que un agente usa herramientas perfectamente legítimas de forma insegura o para algo que no tocaba. Detrás suele haber una inyección de instrucciones que ha salido bien, una tarea mal especificada que deja margen a la ambigüedad o algún fallo a la hora de delegar las acciones.

Dentro del *Tool Misuse*, en entornos agénticos hay tres formas que aparecen con más frecuencia. Una es el *Unvalidated Input Forwarding*, que consiste en reenviar entradas sin validar a herramientas críticas. Otra es el *Tool Pivot*, donde se ejecutan comandos ocultos que iban camuflados en instrucciones de apariencia inofensiva. Y la tercera es encadenar varias herramientas internas para conseguir algo que los diseñadores del sistema nunca previeron, incluso sin salirse de los privilegios que estaban formalmente concedidos [11], [14].

El impacto potencial de esta vulnerabilidad es significativamente mayor que el de la inyección de *prompts* aislada, ya que la explotación exitosa puede derivar en exfiltración de datos persistentes, modificación de registros en bases de datos corporativas, invocación de API de terceros con consecuencias económicas directas o escalada de privilegios dentro del flujo de ejecución del agente [14]. La mitigación requiere la aplicación del principio de mínimo privilegio en la definición de herramientas disponibles, la validación semántica de entradas antes de su propagación, y la exigencia de supervisión humana para acciones de alto impacto [8], [14].

3.3.3. Exceso de agencia (*Excessive Agency*)

La vulnerabilidad **LLM06:2025 *Excessive Agency*** [8] describe la situación en la que un agente LLM recibe permisos, funciones o un grado de autonomía que excede lo estrictamente necesario para la ejecución de sus tareas asignadas. Este sobredimensionamiento de capacidades amplía la superficie de ataque explotable y puede traducirse en acciones potencialmente dañinas cuando el agente recibe prompts ambiguos, manipulados o maliciosos.

En el contexto operativo de una arquitectura agéntica, el *Excessive Agency* puede manifestarse en tres dimensiones complementarias. En la de

permisos, cuando el modelo tiene acceso a herramientas o recursos que no son necesarios para su función principal. En la de *funcionalidad*, cuando se habilitan capacidades de escritura, eliminación o modificación en entornos donde solo debería existir acceso de lectura. Y en la de *autonomía*, cuando el agente puede tomar decisiones irreversibles sin necesidad de confirmación humana [8], [11].

La relación entre el *Excessive Agency* y el *Tool Misuse* es estrecha: el primero genera las condiciones estructurales que hacen posible el segundo. Desde el punto de vista de la evaluación de seguridad, esta interdependencia exige que los benchmarks diseñados para arquitecturas agénticas no se limiten a evaluar la capacidad del modelo para resistir ataques de inyección, sino que también contemplen su comportamiento cuando tiene a su disposición herramientas cuyo uso no está explícitamente prohibido por el contexto del sistema [11].

Mitigar el *Excessive Agency* pasa por adoptar el principio de mínimo privilegio en el diseño de herramientas, restringir las capacidades a las estrictamente necesarias para cada rol e incorporar controles de autorización en los sistemas externos con los que interactúa el LLM [8].

3.3.4. Denegación de servicio semántica (SDoS)

Un vector de amenaza emergente y de creciente relevancia en arquitecturas agénticas es la *Semantic Denial of Service* (SDoS), también denominada *over-refusal* inducido adversarialmente. Este ataque explota las políticas de alineación de seguridad del modelo para provocar que rechace solicitudes legítimas, degradando su disponibilidad funcional sin comprometer directamente su integridad o confidencialidad [11].

A diferencia de los ataques de denegación de servicio a nivel de red o infraestructura, el SDoS actúa sobre la capa de razonamiento del modelo, induciendo una saturación cognitiva o una interpretación excesivamente conservadora de las políticas de seguridad embebidas en el *system prompt*. Este fenómeno es especialmente pronunciado en modelos de menor escala, donde la complejidad de las reglas de seguridad puede superar la capacidad de razonamiento disponible, generando un comportamiento paradójico en el que niveles más elevados de *hardening* inducen una degradación simultánea tanto en la seguridad como en la utilidad operativa del agente [11].

3.4. Mecanismos de defensa: *hardening* del *system prompt*

En el contexto de las arquitecturas agénticas evaluadas en entornos de inferencia local, el *system prompt* constituye la principal —y en muchos escenarios la única— barrera defensiva entre el agente y los vectores de ataque descritos [11]. Su naturaleza como contexto de inicialización del razonamiento del modelo lo convierte en el componente con mayor superficie de control disponible para el operador, sin necesidad de modificar los pesos del modelo ni de intervenir en la capa de infraestructura de ejecución.

La práctica de *hardening* o endurecimiento del *system prompt* se refiere al diseño sistemático de instrucciones de contexto que fortalecen la robustez operativa del agente frente a entradas adversarias, limitando su superficie de decisión y estableciendo políticas de seguridad verificables en lenguaje natural [11]. Este mecanismo ha sido objeto de creciente atención en la literatura técnica debido a su bajo coste de implementación y a su capacidad para mejorar la resistencia del modelo sin requerir acceso a los parámetros internos.

3.4.1. Niveles de endurecimiento y su impacto operativo

La investigación experimental sobre los efectos del *hardening* ha conducido a la definición de niveles progresivos de restricción, cada uno de los cuales configura un paradigma de seguridad diferente [11]:

1. **Nivel inductor** (*baseline*): configuración permisiva basada en confianza implícita en el modelo. No contiene restricciones técnicas activas ni políticas de seguridad explícitas. Proporciona la línea base de comportamiento natural del modelo ante entradas adversarias.
2. **Nivel estricto**: introduce reglas claras en lenguaje natural y restricciones técnicas específicas sobre acciones sensibles, rutas de ficheros autorizadas y prohibición explícita de exfiltración de información sensible. Actúa como un cortafuegos semántico basado en reglas declarativas.
3. **Nivel ultra**: implementa un paradigma de seguridad crítica y desconfianza sistemática, obligando al modelo a verificar internamente el cumplimiento de las políticas de seguridad antes de ejecutar cualquier acción. Incorpora mecanismos de auto-auditoría, priorización explícita de tareas legítimas y rechazo proactivo de instrucciones ambiguas.

Cuando se prueban estos niveles sobre modelos de código abierto ejecutados en local, los resultados no son iguales para todos: cambian bastante

según el tamaño del modelo y según lo especializado que esté. Lo que se observa es que el endurecimiento por contexto rinde en función de la capacidad de razonamiento del modelo. En arquitecturas grandes o muy especializadas funciona bien, pero los modelos pequeños tienden a saturarse cuando se les mete en contextos demasiado restrictivos, y esa saturación llega a echar por tierra parte de la protección que en teoría se buscaba [11].

Esto casa con lo que en la literatura se conoce como *inverse scaling law*: en ciertas tareas de seguridad, los modelos más pequeños acaban siendo, contra toda intuición, más vulnerables a las instrucciones directas justo cuando los mecanismos de control les sobrecargan la capacidad de razonar [11]. De cara a montar agentes en producción, donde el cómputo está limitado, la consecuencia es clara: elegir el modelo pasa por buscar un punto medio entre latencia, coste y robustez.

3.4.2. Entornos de ejecución local y reproducibilidad de *benchmarks*

Para medir si el *hardening* funciona hacen falta entornos de ejecución que cumplan dos condiciones: que los resultados se puedan reproducir y que el comportamiento del modelo quede aislado de intermediarios ajenos. Ahí, correr los LLM en infraestructuras locales de inferencia (por ejemplo con las herramientas de *serving* de modelos de código abierto) tiene ventajas claras sobre las API comerciales cuando de lo que se trata es de evaluar seguridad. Por un lado, se descarta que una capa de filtrado externa acabe alterando el comportamiento real del modelo que estamos poniendo a prueba. Por otro, se puede medir la latencia de inferencia con precisión, sin el *overhead* variable que introduce la red. Y, además, se conserva una trazabilidad completa de todas las configuraciones que se han evaluado [11].

La reproducibilidad constituye un requisito metodológico no negociable en la investigación de seguridad en LLM. Los *benchmarks* estáticos, basados en colecciones fijas de prompts adversarios, presentan limitaciones estructurales frente a modelos que tienden a memorizar y bloquear patrones de ataque conocidos. La adopción de *frameworks* de generación adversaria dinámica (como PyRIT de Microsoft [9]), combinada con motores de evaluación deterministas basados en aserciones programáticas, como *Promptfoo*, en lugar de evaluadores basados en LLM (*LLM-as-a-judge*), permite garantizar que los resultados obtenidos sean reproducibles, libres de variabilidad estocástica del evaluador y comparables entre distintas configuraciones de modelo [11], [12].

3.4.3. Limitaciones de los mecanismos basados en *system prompt*

El *hardening* del *system prompt* no constituye una solución suficiente por sí sola para garantizar la seguridad de un agente LLM en producción. Su eficacia está fundamentalmente limitada por la capacidad de razonamiento del modelo subyacente, el tamaño de la ventana de contexto disponible y la naturaleza no determinista del proceso de inferencia. En contextos con ventanas de contexto extensas, las directivas de seguridad embebidas en el *system prompt* pueden ver degradada su influencia sobre el razonamiento del modelo, un fenómeno conocido como *attention dilution* o pérdida de atención contextual [11].

El carácter no determinista de los LLM y la continua evolución de las técnicas de evasión adversaria hacen que ninguna configuración estática del *system prompt* pueda garantizar una resistencia absoluta. Por este motivo, la investigación actual apunta hacia una estrategia de defensa en profundidad que combina el *hardening* contextual con controles a nivel de infraestructura —validadores de esquema, filtros de salida, mecanismos de supervisión humana para acciones críticas— y con evaluaciones periódicas mediante *red teaming* automatizado [8], [11], [12].

3.5. Síntesis crítica y motivación de la investigación

Si se juntan los marcos de referencia, los *benchmarks* y los estudios que se han ido comentando a lo largo del capítulo, el panorama que queda es el de un campo que va madurando pero que todavía está roto en pedazos. El NIST AI RMF da una buena base para la gobernanza a nivel institucional, pero no baja al detalle técnico que haría falta para localizar vectores de ataque en arquitecturas agénticas [10]. OWASP aporta taxonomías que se han vuelto imprescindibles, como *Tool Misuse* o *Prompt Injection*, y sin embargo se queda corto en cuanto se le piden métricas operativas o escenarios de agentes que realmente actúan [8], [14]. Y MITRE ATLAS sirve para poner cada TTP frente a un incidente real, aunque al final su papel es más el de describir que el de medir [7].

Con los *benchmarks* pasa algo parecido. Los que hay publicados, como AdvBench, PromptBench, CyberSecEval o TruthfulQA, miran casi siempre al texto: toxicidad, alucinaciones, información falsa o aguante frente a *prompts* adversarios de entrada y salida. Lo que no hacen es evaluar de forma directa a un agente que ejecuta acciones sobre sistemas externos [11]. AIRTBench es de los pocos que empieza a asomarse a esa parte operativa, con escenarios al estilo *capture-the-flag*, y va por buen camino, pero de momento cubre poco de lo que es específico del *tool calling*.

Al final, lo que no aparece por ningún lado en la bibliografía revisada es algo que una los dos extremos: el ataque automatizado, por un lado, y la corrección concreta sobre la plataforma afectada, por el otro. Los marcos que hemos visto clasifican muy bien los problemas, pero ninguno te dice qué hay que tocar exactamente en **SharePoint** o en **Microsoft Purview**. Ese es justo el hueco que este trabajo se propone llenar.

Capítulo 4

Diseño de la propuesta

4.1. Descripción general del sistema

El sistema que se propone en este trabajo, **Generative AI Hardening Framework** (GAIHF), surge para tapar un hueco muy concreto en la seguridad de las aplicaciones de IA generativa dentro de la empresa. Cuando una organización empieza a usar herramientas como **Microsoft Copilot**, el punto débil ya no está tanto en la infraestructura de siempre, sino que se traslada a otro sitio: a lo que el modelo es capaz de entender y a los permisos con los que accede a los datos.

GAIHF actúa como un puente automatizado entre las operaciones ofensivas de *AI Red Teaming* y la remediación defensiva. A diferencia de las herramientas de seguridad estáticas, que solo analizan configuraciones, este sistema se apoya en las evidencias empíricas que dejan los ataques controlados para orientar la remediación. Ese ciclo de realimentación se utiliza como marco de diseño; su cierre empírico —aplicar el *hardening* sobre el *tenant* y volver a lanzar la campaña— se plantea como trabajo futuro (Capítulo 7).

4.1.1. Componentes nucleares

El flujo de trabajo se orquesta mediante la interacción de dos grandes bloques funcionales que separan la fase de descubrimiento de la fase de resolución:

- **Motor de emulación adversarial (basado en PyRIT):** este módulo utiliza la librería *Python Risk Identification Tool* desarrollada por Microsoft [9]. Su función es orquestar y lanzar la campaña de ataque. Se ha personalizado mediante un *target* propio (**CopilotChatTarget**) que se comunica con **Copilot** a través de la API de **Microsoft Graph**, y




Figura 4.1: Representación general del sistema

un generador *few-shot* que produce peticiones de enumeración directa a partir de un conjunto de *prompts* semilla verificados.

- **Motor de recomendación inteligente (desarrollo propio):** es la parte original del sistema. Funciona como un analista de seguridad que procesa los registros de ataques, fallidos y exitosos, y cruza los hallazgos con un catálogo estático de controles de referencia (CIS, MITRE ATLAS y OWASP LLM) mediante llamadas especializadas a un modelo de lenguaje. Incorporar un mecanismo de *Retrieval-Augmented Generation* (RAG) que recupere de forma dinámica la guía de endurecimiento más actual de cada proveedor queda planteado como mejora futura (Capítulo 7).

4.2. Arquitectura del sistema y flujo de datos

La arquitectura de GAIHF se basa en un modelo micro-modular que garantiza la escalabilidad y la facilidad de actualización ante nuevas variantes de ataques adversariales.

4.2.1. Fases del ciclo de vida de una auditoría

El sistema opera mediante un ciclo operativo de cuatro fases, detalladas a continuación:

4.2.1.1. Fase 1: Orquestación de ataques adversariales

En esta fase, que se ejecuta con el *framework* PyRIT, se lanza contra una campaña de enumeración directa por *oversharing*: peticiones sencillas y directas ("lista", "genera un fichero con", "localiza") con las que se le pide al asistente que inventaríe y recupere contenido del *tenant*. Partiendo de un conjunto de *prompts* semilla que se verificaron manualmente, un modelo auxiliar de lenguaje genera de forma automática nuevas peticiones dentro del mismo dominio. No hay *jailbreak* ni sesiones multi-turno diseñadas para evadir controles: el asistente responde a estas peticiones simplemente porque el usuario tiene acceso de lectura al contenido, fruto de una configuración de permisos deficiente.

4.2.1.2. Fase 2: Persistencia y *scoring* semántico

Cada intercambio entre el atacante simulado y el *target* se guarda en una base de datos **SQLite**. Para decidir si un ataque salió bien no nos fiamos de una impresión, sino de un criterio determinista: lo damos por exitoso cuando la respuesta de **Copilot** cita al menos un fichero real del *tenant* en sus atribuciones de *grounding*, es decir, cuando aparecen enlaces a **SharePoint** u **OneDrive** corporativos. Al margen de eso, un *scorer* apoyado en un modelo de lenguaje (una escala *Likert* de privacidad) mide cómo de grave es el contenido que ha quedado al descubierto. Separar ambas cosas tiene su razón de ser: si el éxito dependiera solo del juicio de un LLM acabaríamos arrastrando falsos positivos, y de esta forma los evitamos.

4.2.1.3. Fase 3: Interpretación de brechas de seguridad

Cuando la campaña termina, el motor de recomendación inteligente se pone a repasar los "puntos calientes" de la base de datos, buscando aquellos casos en los que el modelo ha fallado una y otra vez. Esta fase es crucial porque diferencia entre una alucinación del modelo y un fallo estructural en los permisos de acceso a datos del *tenant*.




Figura 4.2: Diagrama de secuencia: Ataque de AI *Red Teaming*

4.2.1.4. Fase 4: Generación de artefactos de bastionado

El sistema produce informes técnicos (Markdown, JSON y HTML) con recomendaciones de configuración priorizadas. Para entornos Microsoft, sugiere directivas concretas de Microsoft Purview [17] (etiquetas de sensibilidad o políticas de prevención de pérdida de datos (DLP)) junto con la ruta exacta de configuración en el portal de administración.

4.3. Diseño detallado del motor de recomendación

El motor de desarrollo propio sigue un flujo lógico que convierte los datos brutos de los ataques en recomendaciones concretas.

4.3.1. Algoritmo de priorización de hallazgos

Para evitar la fatiga por alertas, se ha implementado un sistema de puntuación de criticidad basado en tres vectores:

1. **Sensibilidad del dato exfiltrado:** basado en el mapeo previo de activos (PII, secretos financieros, etc.).

2. **Complejidad del ataque:** se penaliza más aquello que es fácil de explotar con *prompts* sencillos.
3. **Persistencia del fallo:** si el ataque tiene éxito en múltiples ejecuciones bajo diferentes contextos.

4.4. Introducción y justificación del diseño

4.4.1. Por qué no extender PyRIT directamente

La alternativa más obvia habría sido contribuir directamente al repositorio de PyRIT, pero se descartó por razones de diseño. PyRIT tiene un objetivo muy claro —atacar— y mezclar en el mismo código la lógica de mediación habría roto esa cohesión. Además, la herramienta necesita guardar un historial entre ejecuciones para poder mostrar tendencias, y eso requiere estado persistente que PyRIT no contempla. El resultado de separar ambas herramientas es que GAIHF puede trabajar también con resultados de otras herramientas de red teaming, no solo con PyRIT.

4.4.2. Justificación del uso de Azure OpenAI

La elección de **Azure OpenAI** [18] como motor de análisis responde a dos motivos, uno técnico y otro de gobernanza. Desde el punto de vista técnico, los modelos disponibles en **Azure** —en este trabajo, **gpt-5-mini**— tienen capacidad de razonamiento suficiente para analizar patrones de ataque, detectar qué controles han fallado y redactar recomendaciones coherentes con el contexto de cada plataforma. En lo relativo a la gobernanza, **Azure OpenAI** garantiza que los datos procesados no se utilizan para entrenar modelos futuros, un requisito habitual en entornos corporativos donde los resultados de un red teaming revelan la postura de seguridad de la organización [19].

Como ventaja adicional, la integración con el ecosistema Microsoft —en el que también se enmarca **Copilot for Microsoft 365**— facilita la coherencia administrativa y de autenticación en despliegues reales.

4.5. Arquitectura general del sistema

La arquitectura de GAIHF sigue un patrón de *pipeline* de procesamiento en cuatro capas [20], donde cada capa tiene una responsabilidad única y bien definida, y la comunicación entre capas se realiza mediante estructuras de datos normalizadas en formato diccionario Python.




Figura 4.3: Arquitectura de GAIHF, repartida en cuatro capas de procesamiento. Las capas se comunican entre sí pasándose diccionarios `Python` con un esquema normalizado.

4.5.1. Capa 1: Entrada y validación

Esta capa es responsable de aceptar datos en múltiples formatos de origen y producir un único diccionario normalizado que el resto del sistema consume. Está compuesta por tres módulos:

- `core/validator.py`: Valida la estructura del JSON de PyRIT antes de cualquier procesamiento.
- `core/pyrit_parser.py`: Normaliza el JSON validado al esquema interno del sistema.
- `pyrit_exporter.py`: Convierte fuentes alternativas (CSV, DuckDB) al formato JSON esperado.

4.5.2. Capa 2: Análisis mediante IA

Esta capa delega el análisis semántico de las vulnerabilidades y la generación de recomendaciones al modelo de lenguaje de `Azure OpenAI`. Está compuesta por:

- `core/azure_client.py`: Encapsula la comunicación con `Azure OpenAI` con gestión de reintentos.
- `core/evaluator.py`: Orquesta cuatro llamadas secuenciales al modelo con prompts especializados.

4.5.3. Capa 3: Scoring determinista

Esta capa calcula métricas objetivas y reproducibles sin intervención del modelo de lenguaje:

- `core/scoring.py`: Motor de cálculo de métricas de madurez, ROI y proyecciones.
- `config/hardening_controls.py`: Catálogo estático de controles de referencia (CIS, MITRE ATLAS, OWASP).

4.5.4. Capa 4: Salida y persistencia

Esta capa es responsable de transformar el resultado del análisis en artefactos consumibles:

- `core/report_generator.py`: Genera informes en *Markdown*, *JSON* y *HTML*.
- `core/logger.py`: Registra cada ejecución en el log de auditoría persistente.
- `core/trend_reporter.py`: Genera informes de tendencia multi-ejecución.

4.5.5. Flujo de datos completo

El flujo de datos entre capas sigue la secuencia representada en la Figura 4.4. El punto de entrada es el archivo *JSON* de PyRIT —o su equivalente generado por el exportador—, que atraviesa la capa de validación y parseo para producir el diccionario normalizado. Este diccionario alimenta simultáneamente al evaluador de IA y al motor de *scoring*. Ambos resultados convergen en el generador de informes, que produce los artefactos de salida, y el *logger* persiste los metadatos de la ejecución.

4.6. Módulo de validación y parseo

4.6.1. Diseño del validador de esquema

El módulo `core/validator.py` implementa un validador de esquema para el *JSON* de PyRIT sin dependencias externas, utilizando exclusivamente la biblioteca estándar de Python. La decisión de no utilizar bibliotecas de




Figura 4.4: Recorrido completo de los datos en GAIHF, desde que entra el JSON de PyRIT hasta que se generan los informes y se registra la auditoría.

validación como **Pydantic** o **Cerberus** responde al requisito RNF-01 de minimizar dependencias.

El diseño distingue explícitamente entre dos tipos de problemas: errores bloqueantes y advertencias. Los errores bloqueantes impiden el procesamiento (por ejemplo, que falte el campo `overall_score` o que aparezca un valor de `outcome` no reconocido) y se comunican lanzando un `ValueError` con un mensaje descriptivo que indica qué campo falta exactamente y en qué posición del JSON. Las advertencias señalan condiciones subóptimas que no impiden el procesamiento (por ejemplo, la ausencia de `platform_breakdown`) y se comunican mediante mensajes en consola, de modo que el análisis pueda continuar con valores por defecto.

Esta distinción sigue el principio de *fail fast* para errores estructurales [21] mientras mantiene la tolerancia a fallos para campos opcionales. El resultado de la validación se encapsula en un objeto `ValidationResult` que expone tres atributos: `ok` (booleano), `errors` (lista de mensajes de error) y `warnings` (lista de advertencias).

Los valores válidos para el campo `outcome` de cada conversación son: `SUCCESS`, `FAILED`, `PARTIAL`, `UNKNOWN` y `ERROR`. El validador también detecta incoherencias numéricas: si `successful_attacks` + `failed_attacks` $\neq$ `total_conversations`, se emite una advertencia que previene al usuario de

posibles errores de exportación desde PyRIT.

4.6.2. Normalización del esquema de PyRIT

El módulo `core/pyrit_parser.py` produce un diccionario con un esquema normalizado independiente de la versión de PyRIT que haya generado el JSON de entrada. Esta normalización es necesaria porque PyRIT ha evolucionado significativamente a lo largo de sus versiones, cambiando el nombre y la estructura de varios campos [9]. La versión de referencia de este TFG es PyRIT **0.12.0** (microsoft/PyRIT, marzo 2026), que introdujo cambios relevantes respecto a versiones anteriores: migración del repositorio de Azure/PyRIT a microsoft/PyRIT, nuevo sistema de configuración YAML en `~/.pyrit/.pyrit_conf`, soporte de SQLite además de DuckDB como *backend* de memoria, nuevos *orchestrators* (`PromptSendingOrchestrator`, `CrescendoOrchestrator`), y corrección de una vulnerabilidad de inyección Jinja2 mediante `SandboxedEnvironment`. La herramienta mantiene compatibilidad hacia atrás con versiones 0.4.x a 0.11.x.

El esquema normalizado de salida contiene los siguientes campos principales:

- `overall_score`: score global de PyRIT (0–10).
- `risk_band`: banda de riesgo calculada (BAJO, MEDIO, ALTO, CRÍTICO).
- `vulnerabilities`: lista de conversaciones con outcome SUCCESS o PARTIAL.
- `harm_categories`: frecuencia de cada categoría de daño detectada.
- `platform_scores`: scores desagregados por plataforma SaaS.
- `success_rate`: proporción de ataques exitosos sobre el total.
- `raw`: datos originales sin modificar, para trazabilidad.

La asignación de banda de riesgo sigue el esquema de cuatro niveles de la Tabla 4.1.

4.7. Diseño del módulo de evaluación con IA

4.7.1. Justificación de la arquitectura *multi-prompt*

El componente central del sistema es el módulo `core/evaluator.py`, que orquesta la comunicación con Azure OpenAI para generar el análisis de

Tabla 4.1: Correspondencia entre score PyRIT y banda de riesgo.

Score PyRIT	Banda	Descripción
[8.0, 10.0]	CRÍTICO	Ataques exitosos con alto impacto potencial
[6.0, 8.0)	ALTO	Múltiples vectores explotables con esfuerzo moderado
[4.0, 6.0)	MEDIO	Vulnerabilidades parciales o de baja severidad
[0.0, 4.0)	BAJO	Superficie de ataque mínima o bien controlada

seguridad. La decisión de diseño más relevante de este módulo es la de utilizar cuatro llamadas secuenciales independientes en lugar de un único *prompt* que lo cubra todo.

La decisión de usar cuatro llamadas independientes en lugar de un único prompt muy largo surgió de la práctica, no de la teoría. En las primeras pruebas con un *prompt* unificado, el modelo empezaba a truncar las recomendaciones de hardening cuando el mismo prompt acumulaba también el análisis ejecutivo y técnico, y el JSON de salida era inconsistente. Dividir el análisis en llamadas especializadas —una para el ejecutivo, otra para la parte técnica y otra para el *hardening*— resultó en respuestas más precisas y formato más estable.

4.7.2. Los *system prompts* especializados

El sistema define dos system prompts diferenciados, utilizados en cuatro llamadas:

4.7.2.1. SYSTEM_PROMPT_MAIN

Este *prompt* define al modelo como experto en seguridad de IA especializado en *AI Red Teaming*. Es utilizado en tres de las cuatro llamadas: análisis ejecutivo, evaluación técnica y plan de acción. Instruye al modelo a:

- Basar sus respuestas exclusivamente en los datos proporcionados, sin asumir contexto externo.
- Priorizar las recomendaciones por criticidad (CRÍTICO > ALTO > MEDIO > BAJO).
- Redactar en español con terminología técnica de ciberseguridad.
- Responder exclusivamente en *JSON* válido siguiendo el esquema especificado en el *user message*.




Figura 4.5: Diagrama de secuencia con las cuatro llamadas que se hacen a Azure OpenAI: análisis ejecutivo, evaluación técnica, *hardening* de Microsoft 365 y plan de acción.

4.7.2.2. SYSTEM_PROMPT_HARDENING_M365

Este *prompt* especializa al modelo en el ecosistema de seguridad de Microsoft 365, con conocimiento explícito de: Microsoft Entra ID y Conditional Access, Microsoft Purview (DLP, *Information Protection*), Microsoft Defender for Office 365, Copilot for Microsoft 365 y sus controles, *Privileged Identity Management* (PIM) y Microsoft Secure Score. Las recomendaciones deben incluir la ruta exacta de configuración en el portal (por ejemplo: Microsoft 365 Admin Center → Seguridad → Acceso condicional).

4.7.3. Secuencia de llamadas y estructura del output

La Figura 4.5 muestra el diagrama de secuencia de las cuatro llamadas a Azure OpenAI y el flujo de información entre ellas.

Cada llamada genera un fragmento del diccionario de evaluación. La llamada 1 produce el análisis ejecutivo (resumen, hallazgos principales, urgencia, impacto en el negocio). La llamada 2 produce la evaluación técnica (vulnerabilidades críticas con CVSS estimado, patrones de ataque, superficies de ataque, brechas en controles existentes). La llamada 3 produce las recomendaciones de *hardening* para Microsoft 365 (lista de recomendaciones con ID, prioridad, categoría, acción, ruta administrativa, esfuerzo y tiempo).

estimado). La llamada 4 produce el plan de acción en tres fases temporales con KPI de seguimiento y score objetivo.

A estas cuatro llamadas principales se añade una quinta, condicional, que solo se ejecuta cuando la campaña ha expuesto ficheros concretos del *tenant*: genera las recomendaciones de *hardening* personalizadas por activo, que citan cada recurso afectado por su nombre (véase el Capítulo 6). Cuando la campaña no arroja activos, este paso se omite y el flujo se reduce a las cuatro llamadas del núcleo.

4.7.4. Gestión de temperatura y parámetros del modelo

Para un caso de uso de análisis de seguridad, se configuró una temperatura de **0,2** (en lugar del valor por defecto de 1,0). La idea viene de lo que recomienda la propia documentación de **Azure OpenAI** [22] para tareas en las que interesa que la respuesta sea precisa y repetible, no creativa. Con la temperatura baja, el modelo suele devolver un JSON más estable y que apenas cambia de una ejecución a otra si le damos los mismos datos de entrada. En cuanto a **max_tokens**, se dejó en 4.096 para casi todas las llamadas, salvo en la de recomendaciones por activo, que al ser más larga se subió a 8.000 para que la respuesta no se corte a medias.

4.7.5. Mecanismo de tolerancia a fallos en el parseo

Dado que los modelos de lenguaje pueden ocasionalmente envolver su respuesta en bloques de código Markdown (“`json`”), se implementó el método estático `_safe_parse_json()` que limpia estos delimitadores antes de llamar a `json.loads()`. Si el parseo falla, el método retorna un diccionario con la clave `_parse_error: True` y el texto en bruto, en lugar de lanzar una excepción. Esto evita que un único fallo de formato cancele todo el análisis.

4.7.6. Gestión de reintentos en el cliente de Azure

El módulo `core/azure_client.py` reintenta automáticamente ante dos tipos de error transitorio: `RateLimitError` (se ha superado la cuota de solicitudes o de tokens por minuto) y `APIConnectionError` (fallos de red). Ante un 429, la espera toma el máximo entre la cabecera `Retry-After` que devuelve **Azure** y un *backoff* exponencial con un suelo mínimo —este suelo es necesario porque el servicio a menudo responde `Retry-After: 1` aunque la cuota siga agotada—, hasta un tope de seis intentos. Los errores 4xx de configuración (credenciales inválidas o *deployment* inexistente) no se reintentan, por no ser transitorios.

4.8. Motor de *scoring* determinista

4.8.1. Justificación del enfoque determinista

Una de las decisiones de diseño que más pesan en el sistema es que **parte del *scoring* no pasa por la IA**. Detrás hay dos razones. La primera es la **reproducibilidad**: cuando hablas de seguridad corporativa, necesitas que las métricas de riesgo se puedan auditar y comparar de una ejecución a otra. Si ese *scoring* lo marcara el modelo de lenguaje, el mismo conjunto de vulnerabilidades podría dar proyecciones distintas según el día, y ahí se acabó cualquier comparación entre rondas de red teaming. La segunda es la **trazabilidad**: cada número que sale del módulo de *scoring* se puede reconstruir a mano desde los datos de entrada siguiendo las cuentas, de modo que, si hace falta, cualquiera puede comprobar de dónde viene.

Ahora bien, conviene ser claro con lo que este determinismo garantiza y lo que no. El cálculo es reproducible *para una entrada dada*, pero se apoya en **constantes heurísticas**: tanto los pesos por categoría de daño (Tabla 4.2) como las reducciones de riesgo por nivel de prioridad (Tabla 4.3) se fijaron a partir de marcos como CVSS y de lo que cuentan los informes de incidentes, no de una calibración empírica. Dicho de otro modo, que sea reproducible **no significa que sea válido**: los valores absolutos que devuelve el motor hay que leerlos como estimaciones ilustrativas, no como algo medido. Y hay un detalle más que merece la pena dejar dicho: la reducción de riesgo de cada recomendación se asigna según su nivel de prioridad, y esa prioridad la pone el modelo de lenguaje en la capa de análisis (Sección 4.7). Así que, aunque la cuenta en sí sea determinista, una de sus entradas, la prioridad, no lo es del todo: una misma vulnerabilidad podría llevarse prioridades diferentes en ejecuciones distintas y, con ellas, proyecciones diferentes. El *scoring* determinista estrecha esa variabilidad y la deja auditable, pero no la hace desaparecer.

4.8.2. *Score* de riesgo compuesto

El *score* de riesgo compuesto pondera el *score* global de PyRIT por la gravedad promedio de las categorías de daño detectadas. La fórmula es:

$$S_{\text{compuesto}} = S_{\text{PyRIT}} \cdot \frac{\sum_i w_i \cdot c_i}{\sum_i c_i} \quad (4.1)$$

donde S_{PyRIT} es el *score* global de PyRIT (0–10), c_i es el número de conversaciones de la categoría de daño i y w_i es el peso asignado a esa categoría. Los pesos se definieron en función de la gravedad potencial de cada tipo de daño para una organización empresarial (Tabla 4.2).

Tabla 4.2: Pesos heurísticos asignados a cada categoría de daño para el cálculo del score de riesgo compuesto. Son valores orientativos, fijados por criterio experto y no calibrados empíricamente.

Categoría de daño	Peso (w_i)	Justificación
data_exfiltration	1,00	Máxima gravedad: pérdida directa de datos sensibles
credential_exposure	1,00	Compromiso de identidades con acceso persistente
prompt_injection	0,90	Vector de ataque de amplio alcance
dlp_bypass	0,85	Evasión de controles técnicos existentes
privilege_escalation	0,80	Acceso a recursos no autorizados
policy_bypass	0,70	Violación de políticas corporativas
social_engineering	0,65	Requiere interacción humana adicional
unknown	0,50	Gravedad indeterminada

4.8.3. Score de madurez de *hardening*

El *score* de madurez refleja la solidez de los controles de seguridad existentes en la organización en relación con el riesgo detectado. Se calcula como:

$$M = \left(1 - \frac{S_{\text{PyRIT}}}{10}\right) \cdot 100 \cdot \alpha \quad (4.2)$$

donde α es un factor de penalización. Cuando $S_{\text{PyRIT}} \geq 7.0$ y no se identificaron recomendaciones críticas en el análisis de IA, $\alpha = 0.7$; en caso contrario, $\alpha = 1.0$. Esta penalización refleja la inconsistencia entre un riesgo elevado y la ausencia de controles críticos identificados, lo que normalmente indica una evaluación incompleta.

4.8.4. ROI de seguridad de cada recomendación

Para priorizar las recomendaciones más allá de su nivel de criticidad, se calcula un indicador de *Return on Investment* de seguridad:

$$\text{ROI}_i = \frac{\Delta r_i}{h_i/8} \quad (4.3)$$

donde Δr_i es la reducción de riesgo estimada por implementar la recomendación i (Tabla 4.3) y h_i son las horas de esfuerzo estimadas normalizadas a días de trabajo (dividiendo entre 8). Este indicador permite identificar las recomendaciones con mayor impacto por unidad de esfuerzo, que son los denominados *quick wins*.

Tabla 4.3: Reducción de riesgo y esfuerzo estimados por nivel de prioridad. Se trata de constantes heurísticas (derivadas de CVSS y de informes de incidentes), no de valores medidos; determinan las proyecciones del motor de *scoring* y deben interpretarse como orientativas.

Prioridad	Reducción riesgo (Δr)	Esfuerzo típico (h)
CRÍTICA	25 %	8 h (1 día)
ALTA	15 %	8 h (1 día)
MEDIA	8 %	24 h (3 días)
BAJA	3 %	2 h (fracción de día)

4.8.5. Proyección por fases con rendimientos decrecientes

La reducción de riesgo acumulada tras implementar un conjunto de recomendaciones no es aditiva: cada recomendación sucesiva tiene menos impacto porque el riesgo residual es menor. El sistema modela esto mediante la fórmula de rendimientos decrecientes:

$$r_{\text{acum}}^{(k)} = r_{\text{acum}}^{(k-1)} + \Delta r_k \cdot (1 - r_{\text{acum}}^{(k-1)}) \quad (4.4)$$

donde $r_{\text{acum}}^{(k)}$ es la reducción acumulada tras implementar las k primeras recomendaciones (ordenadas por ROI) y Δr_k es la reducción unitaria de la recomendación k -ésima. Esta fórmula garantiza que $r_{\text{acum}} \in [0, 1]$ siempre.

Las proyecciones se calculan para tres fases temporales: Fase 1 (0–30 días, solo recomendaciones CRÍTICAS), Fase 2 (30–90 días, CRÍTICAS y ALTAS) y Fase 3 (90–180 días, todas las recomendaciones). El score PyRIT proyectado al final de cada fase se obtiene como $S_{\text{proyectado}} = S_{\text{actual}} \cdot (1 - r_{\text{acum}})$.

4.9. Catálogo de controles de referencia

4.9.1. Selección de *frameworks*

El módulo `config/hardening_controls.py` implementa un catálogo estático de controles de referencia que se incluyen automáticamente en los informes junto a las recomendaciones generadas por IA. La selección de *frameworks* responde a la necesidad de anclar las recomendaciones a estándares reconocidos por la industria de ciberseguridad.

Se seleccionaron tres *frameworks* complementarios. **CIS Controls v8** [23] proporciona una base sólida de controles técnicos y de proceso aplicables a cualquier organización, independientemente del sector. Su estructura por niveles de implementación (IG1, IG2, IG3) facilita la priorización según los recursos disponibles. **MITRE ATLAS** [7] es el *framework* más relevante




Figura 4.6: Proyección *ilustrativa* de cómo iría bajando el *score* de riesgo de Microsoft 365 a lo largo de las distintas fases, calculada por el motor de *scoring* de GAIHF (determinista, aunque apoyado en parámetros heurísticos) sobre los resultados de la campaña de 150 *prompts*. La línea discontinua señala dónde empieza la banda MEDIO: el *score* arranca en torno a 5,6 (MEDIO) y, una vez completado el plan, se queda del orden de 0,2 (BAJO). Son valores orientativos, no una medida real de *antes/después*.

para *AI Red Teaming*, ya que es específico para amenazas a sistemas de IA y aprendizaje automático. Mapea tácticas adversariales como la manipulación de modelos, la inyección de *prompts* y la exfiltración a través de inferencia, que son precisamente las técnicas evaluadas por PyRIT. **OWASP LLM Top 10 (2025)** [8] complementa a MITRE ATLAS con las vulnerabilidades más comunes y críticas específicamente en aplicaciones que utilizan modelos de lenguaje, incluyendo categorías como *prompt injection* (LLM01), divulgación de información sensible (LLM02) y debilidades en instrucciones del sistema (LLM08).

4.9.2. Estructura del catálogo

El catálogo cubre 8 categorías de daño con un total de 23 controles. Cada control incluye los siguientes campos:

- **id**: identificador del control en el *framework* de origen (por ejemplo, CIS-3.13 o ATLAS-AML.T0051).
- **framework**: nombre del *framework*.
- **title**: nombre del control.

- **description**: descripción del riesgo que mitiga.
- **platforms**: lista de plataformas a las que aplica.
- **native_control_m365**: ruta exacta de configuración en Microsoft 365.

La Tabla 4.4 muestra la distribución de controles por categoría de daño y *framework*.

Tabla 4.4: Distribución de controles de referencia por categoría de daño y *framework*.

Categoría de daño	CIS v8	MITRE ATLAS	OWASP LLM	Total
data_exfiltration	2	1	1	4
credential_exposure	2	1	0	3
prompt_injection	1	1	1	3
dlp_bypass	1	0	1	2
privilege_escalation	2	1	0	3
policy_bypass	1	0	1	2
social_engineering	1	1	0	2
harm	3	0	1	4
Total	13	5	5	23

4.10. Del análisis ofensivo al diseño de la herramienta

Lo que salió de la campaña ofensiva fue la materia prima con la que se diseñó y desarrolló GAIHF. El paso de una cosa a la otra fue, sobre todo, un trabajo de síntesis: coger todo ese conocimiento tácito que se había ido acumulando durante las campañas y convertirlo en algo explícito y reproducible, con forma de recomendaciones técnicas ordenadas por prioridad.

Esa síntesis giró en torno a tres actividades:

1. **Mapear los hallazgos a controles de referencia**: cada causa raíz que había aparecido en la campaña se emparejó con los controles que le tocaban en los marcos *CIS Controls* v8 [23], *MITRE ATLAS* [7] y *OWASP LLM Top 10 2025* [8]. Ese emparejamiento es lo que sirvió de base para el catálogo de controles de referencia de GAIHF.
2. **Diseño del esquema de priorización**: a partir de la frecuencia relativa de las causas raíz y de la gravedad potencial de los datos comprometidos, se diseñó el sistema de *scoring* compuesto descrito anteriormente en este capítulo.

3. **Proyección determinista de la reducción de riesgo:** a partir del *score* de riesgo compuesto obtenido de la campaña y del catálogo de controles priorizados, GAIHF calcula de forma determinista un *score* proyectado que estima la reducción de la superficie de ataque tras aplicar el plan de acción por fases (descrito anteriormente en este capítulo).

Es importante precisar el alcance de esta última actividad. La reducción de riesgo que reporta GAIHF es una **proyección determinista de carácter ilustrativo**, derivada de unos pesos y unas reducciones por control fijados de forma heurística (Tablas 4.2 y 4.3); no es una medición empírica *antes/después* sobre el *tenant*. Al operar sobre un entorno corporativo real, no era viable implementar los controles y relanzar la campaña de forma controlada para medir la reducción efectiva. En términos aproximados, sobre un *score* de riesgo base en torno a 5,6/10, la proyección desciende a un nivel bajo (del orden de 0,2/10) tras la implementación completa del plan. Estas cifras deben leerse, por tanto, como una estimación orientativa, no como un valor medido. La **validación empírica de esta proyección** —reejecutar la campaña sobre el *tenant* endurecido— se plantea como línea de trabajo futuro. Los resultados cuantitativos se presentan en detalle en el Capítulo 6.

Capítulo 5

Implementación

Toda el código usado para la implementación de GAIHF se puede encontrar en el repositorio de GitHub de este trabajo: <https://github.com/Moriarty005/GAIHF.git>.

5.1. Generación de informes

5.1.1. Decisión de tres formatos

El sistema genera informes en tres formatos por razones de usabilidad en diferentes contextos organizativos. El formato **Markdown** está diseñado para integrarse en la documentación del proyecto de seguridad en repositorios Git, permitiendo versionar la evolución de la postura de seguridad junto al código. Su texto plano garantiza la compatibilidad con cualquier sistema de gestión de documentación. El formato **JSON** permite la integración automática con otras herramientas del pipeline de seguridad: sistemas SIEM, plataformas de gestión de vulnerabilidades o dashboards propios. El formato **HTML** produce un informe visual con métricas en tarjetas, tablas con prioridades codificadas por color y el plan de acción estructurado, pensado para ser presentado a responsables no técnicos o a la dirección de seguridad.

5.1.2. Estructura del informe *Markdown*

El informe *Markdown* se estructura en siete secciones: (1) tabla de métricas del ejecutivo (score PyRIT, nivel de riesgo, tasa de éxito de ataques), (2) resumen ejecutivo generado por IA, (3) evaluación técnica con tabla de vulnerabilidades críticas y sus CVSS estimados, (4) controles de referencia CIS/ATLAS/OWASP agrupados por categoría de daño, (5) recomendaciones de *hardening* por plataforma ordenadas por prioridad, (6) *scoring* de

hardening con proyecciones por fase y *ranking* de ROI y (7) plan de acción en tres fases con KPI de seguimiento.

La integración de los controles de referencia se realiza automáticamente mediante la función `get_all_controls_for_results()`, que cruza las categorías de daño presentes en los resultados de PyRIT con el catálogo estático. Esto garantiza que solo se incluyan los controles relevantes para los vectores de ataque realmente detectados.




Figura 5.1: Informe HTML que genera GAIHF. Las tarjetas de arriba recogen las métricas clave y, en la tabla de recomendaciones, cada nivel de prioridad tiene su propio color.

5.2. Sistema de auditoría y análisis de tendencia

5.2.1. Diseño del *log* de auditoría

El módulo `core/logger.py` implementa un sistema de auditoría persistente mediante el patrón *append-only log* [24]: cada ejecución añade una línea JSON al archivo `logs/audit.jsonl` sin modificar las entradas anteriores. Es-

ta característica es fundamental para garantizar la integridad del historial de seguridad: en ningún momento se sobrescriben registros previos.

Se eligió el formato JSONL (JSON Lines) [25] frente a alternativas como SQLite o CSV por tres razones: es legible directamente con cualquier editor de texto, permite el procesamiento línea a línea con herramientas Unix estándar (`jq`, `grep`) y es trivialmente importable en herramientas de análisis de datos como `Pandas`.

Cada registro de auditoría contiene: *timestamp* ISO 8601, identificador de ejecución, métricas de PyRIT (score, banda de riesgo, ataques exitosos, tasa de éxito, categorías de daño), métricas de evaluación (nivel de riesgo, plataforma, número de recomendaciones, scores por plataforma), lista de archivos de informe generados y notas libres opcionales.

5.2.2. Informe de tendencia multi-ejecución

El módulo `core/trend_reporter.py` consume el historial de `audit.jsonl` y genera informes de tendencia que muestran la evolución del *posture* de seguridad entre rondas sucesivas de *red teaming*. El informe HTML de tendencia incorpora un gráfico de líneas interactivo implementado con Chart.js [26], que visualiza la evolución del score PyRIT a lo largo del tiempo.

El módulo detecta automáticamente si la tendencia es de **mejora** (delta negativo entre primera y última ejecución) o **regresión** (delta positivo) y adapta el texto del informe en consecuencia. Esta funcionalidad es especialmente relevante para el TFG, ya que permite demostrar con datos objetivos el impacto del proceso de *hardening* entre diferentes rondas de evaluación.

5.2.3. Script de demostración

Para facilitar la evaluación de la funcionalidad de tendencia sin necesidad de ejecutar cuatro rondas reales de PyRIT, el sistema incluye el *script* `demo_trend.py`, que simula cuatro ejecuciones con *scores* decrecientes: 7.8 (*baseline* sin *hardening*), 5.9 (tras implementar *quick wins*), 3.8 (tras controles avanzados) y 2.1 (tras monitorización continua). Esta simulación produce una reducción del 73 % en el score PyRIT, ilustrando el impacto potencial de un plan de *hardening completo*.




Figura 5.2: Ejemplo de informe de tendencia en HTML generado con `trend_reporter.py`, donde se ve cómo evoluciona el score de PyRIT a lo largo de cuatro rondas de *red teaming* aplicando *hardening* entre unas y otras. Los datos salen de la simulación del script `demo_trend.py`.

5.3. Integración con PyRIT

5.3.1. Modalidades de integración

El sistema ofrece tres modalidades de integración con el ecosistema de PyRIT, ordenadas de mayor a menor acoplamiento con la herramienta:

- **Integración programática directa:** el módulo `pyrit_integration.py` expone la función `run_hardening_after_pyrit()`, que puede importarse directamente en un script Python de PyRIT y ejecutarse al finalizar el red teaming sin salir del intérprete Python. Esta modalidad permite pasar el diccionario de resultados del orchestrator de PyRIT directamente, sin necesidad de serialización a disco. El parámetro opcional `generate_trend=True` activa automáticamente la generación del informe de tendencia si hay más de una ejecución registrada.
- **Integración vía CLI:** el usuario exporta los resultados de PyRIT a un archivo JSON y lo pasa como argumento a `main.py`. Esta es la modalidad más común cuando PyRIT y GAIHF se ejecutan en entornos separados o en momentos distintos.
- **Integración vía exportador:** para organizaciones que ya tienen resultados de *red teaming* en formato CSV o en bases de datos DuckDB o SQLite (los backends de memoria de PyRIT 0.12), el módulo `pyrit_exporter.py` convierte estos formatos al JSON estándar del sistema. Para DuckDB y SQLite, el exportador realiza un JOIN entre las tablas `PromptMemoryEntries` y `Scores` del esquema de PyRIT 0.12, normalizando los scores de tipo `float_scale` (rango 0–1) a la escala 0–10 utilizada por GAIHF. Para CSV, el exportador realiza un mapeo flexible de nombres de columna para acomodar variaciones en la nomenclatura.

5.3.2. Compatibilidad con versiones de PyRIT

5.3.3. Compatibilidad con PyRIT 0.12

GAIHF ha sido diseñado tomando PyRIT 0.12.0 como versión de referencia [9]. Los cambios más relevantes de esta versión respecto a las anteriores que afectan a la integración son:

- **Repositorio:** migración de `github.com/Azure/PyRIT` a `github.com/microsoft/PyRIT`.
- **Configuración:** nuevo sistema de configuración YAML centralizado en `~/.pyrit/.pyrit_conf`.

- **Orchestrators:** `PromptSendingOrchestrator` y `CrescendoOrchestrator` son los principales en 0.12, sustituyendo a `RedTeamingOrchestrator` de versiones anteriores.
- **Memoria:** soporte simultáneo de `DuckDB` y `SQLite`. El esquema de la tabla `PromptMemoryEntries` se acompaña de una tabla `Scores` separada, cuyos tipos de score pueden ser `float_scale` (valores 0.0–1.0 que el exportador normaliza a 0–10) o `true_false`.
- **Seguridad de plantillas:** todos los templates Jinja2 se renderizan ahora en `SandboxedEnvironment`, bloqueando accesos inseguros como `__class__` o `__subclasses__`.
- **Estrategias de ataque:** PyRIT 0.12 ofrece diversas estrategias (`SkeletonKeyAttackStrategy`, `CrescendoAttackStrategy`, `PromptInjectionAttackStrategy` etc.). GAIHF es **agnóstico a la estrategia empleada**, pues consume el JSON de resultados con independencia de cómo se generaran; la campaña de enumeración directa de este trabajo (Capítulo 6) se orquestó con `PromptSendingAttack` sobre un *target* propio para Microsoft 365 Copilot.

La compatibilidad hacia atrás con versiones 0.4.x a 0.11.x se mantiene mediante la capa de normalización en `pyrit_parser.py`. La validación de esquema que hace `validator.py` se limita a revisar los campos que se mantienen estables en todas las versiones (`overall_score` y `conversations`), y se conforma con avisar mediante advertencias cuando faltan campos opcionales, algo que puede pasar con las versiones más antiguas.

5.4. Proceso de desarrollo y testing

5.4.1. Metodología de desarrollo

GAIHF se fue construyendo de forma iterativa y por módulos: cada módulo se terminaba entero, con su *suite* de tests incluida, antes de pasar a integrar el siguiente. Trabajar así evitó que al enganchar un módulo nuevo se rompieran los que ya estaban, porque al cerrar cada iteración se lanzaba la suite completa y cualquier regresión saltaba en el momento.

5.4.2. Decisión de no utilizar *pytest*

La *suite* de tests se montó sin recurrir a ninguna dependencia externa, ni siquiera a `pytest`, en línea con el requisito RNF-01 de reducir dependencias al mínimo. Los tests se agrupan en clases con métodos `test_*` y hay un *runner*

propio (`run_tests.py`) que se encarga de descubrirlos e instanciarlos sobre la marcha. Cada módulo de tests puede también ejecutarse directamente como *script* independiente.

5.4.3. Uso de *mocks* para Azure OpenAI

Las *suites* `test_evaluator.py` y `test_integration.py` utilizan la clase `MagicMock` de la biblioteca estándar `unittest.mock` para sustituir el cliente de **Azure OpenAI** con respuestas JSON predefinidas. Este enfoque [27] garantiza que los tests sean:

- **Deterministas**: siempre producen el mismo resultado ante la misma entrada.
- **Rápidos**: no incurren en latencia de red ni costes de API.
- **Independientes**: ejecutables en cualquier entorno sin credenciales de **Azure**.

La variable de entorno `GAIHF_TESTING=1` suprime el *handler* de consola del *logger* durante la ejecución de tests, evitando que los mensajes de *log* contaminen la salida del *runner*.

5.4.4. Cobertura de la *suite* de tests

La Tabla 5.1 resume la cobertura de tests alcanzada por cada módulo del sistema.

Tabla 5.1: Cobertura de la suite de tests de GAIHF (209 tests totales).

Suite	Tests	Aspectos verificados
test_parser	26	Normalización, validación, bandas de riesgo, inventario de activos y parseo de URLs de grounding
test_evaluator	14	Orquestación, parsing JSON (con recuperación de respuestas truncadas), hallazgos por activo, compactado de <i>payload</i> , mocks de Azure
test_azure_client	5	Política de reintentos y <i>backoff</i> ante <i>rate limit</i> (HTTP 429)
test_report_gen	18	Generación de informes, sección de activos afectados, secciones y rutas
test_exporter	16	CSV, DuckDB stubs, cálculos, serialización
test_scoring	28	Scoring compuesto, madurez, ROI, proyecciones
test_logger	25	AuditLogger, JSONL, historial, tendencia
test_validator	27	Errores, advertencias, coherencia de campos
test_controls	30	Catálogo CIS/ATLAS/OWASP, filtros, formato
test_integration	20	Flujo E2E con mocks completos, TrendReporter
Total	209	

```
$ python run_tests.py

=====
GAIHF - Suite de tests
=====

[*] PyRIT Parser                OK 26/26
[*] Security Evaluator          OK 14/14
[*] Azure Client (rate limit)   OK 5/5
[*] Report Generator            OK 18/18
[*] PyRIT Exporter              OK 16/16
[*] Hardening Scorer            OK 28/28
[*] Logger & Audit              OK 25/25
[*] Schema Validator            OK 27/27
[*] Controls Catalog            OK 30/30
[*] Integration & Trend         OK 20/20

-----

[OK] 209/209 tests pasados - TODOS OK (4.4s)
```

Figura 5.3: Salida del *runner* de tests `run_tests.py` mostrando los resultados de las 10 *suites* y el resultado final de 209/209 tests pasados.

Capítulo 6

Evaluación experimental y resultados

Este capítulo reúne la evaluación experimental del trabajo. Primero describe cómo se abordó la parte ofensiva —el enfoque, el entorno de pruebas y el diseño de la campaña de enumeración directa contra **Microsoft 365 Copilot**— y después presenta los resultados: los de la propia campaña (Sección 6.4), los del análisis y el bastionado que GAIHF produce a partir de ellos (Sección 6.5) y una discusión crítica del conjunto (Sección 6.6).

Por motivos de confidencialidad, los nombres de sitios, bibliotecas y ficheros del *tenant* se presentan anonimizados mediante identificadores en clave (“Sitio A”, “**OneDrive-A**”, etc.); se conservan íntegras las magnitudes (número de accesos, severidad y tipo de recurso), que son las relevantes para el análisis.

6.1. Enfoque metodológico general

El problema que se plantea este Trabajo de Fin de Grado, comprobar hasta qué punto aguantan los asistentes de IA generativa metidos en un entorno corporativo y sacar de ahí recomendaciones concretas de bastionado, pide una metodología que sea rigurosa sin dejar de ser aplicable en la práctica. Las herramientas de evaluación estáticas, las que se basan en listas de comprobación o en auditar la configuración a mano, no dan la talla cuando la superficie de ataque es semántica, es decir, cuando su comportamiento no es determinista y depende del contexto [12]. Por eso se optó por un enfoque adversarial empírico: en vez de revisar configuraciones sobre el papel, se pone a prueba al asistente emulando de forma activa a un atacante, y las conclusiones de bastionado se van deduciendo a partir de lo que esos ataques dejan al descubierto.




Figura 6.1: Visión general del enfoque y del ciclo de realimentación *Red Team* / *Blue Team* entre la evaluación ofensiva y el diseño de las recomendaciones.

El trabajo se apoyó en dos etapas encadenadas. En la primera se reconoció el terreno y se preparó el entorno de pruebas: se estudió el ecosistema de ataque de los asistentes de IA empresariales y se configuró un *testbed* SaaS sobre un *tenant* corporativo real. En la segunda se lanzaron las campañas contra Microsoft 365 Copilot, combinando la ingeniería manual de *prompts* con la automatización mediante PyRIT. Los hallazgos de esa evaluación son los que más tarde dieron forma al diseño de GAIHF, que se detalla en el Capítulo 4.

Detrás de esta forma de trabajar está la lógica *Red Team* / *Blue Team*: el atacante saca a la luz un problema y el defensor lo corrige, de modo que cada vuelta deja el sistema algo más robusto (Figura 6.1). Conviene, eso sí, ser honesto con el alcance de ese ciclo. Aquí la realimentación operó durante el desarrollo —los hallazgos ofensivos orientaron el diseño de las recomendaciones—, pero el lazo no llegó a cerrarse del todo: el *hardening* nunca se aplicó sobre el *tenant* para volver a medir la tasa de éxito. Ese cierre empírico queda como la principal línea de trabajo futuro (Sección 7.5).

6.2. Reconocimiento y entorno de experimentación

6.2.1. Revisión sistemática de la literatura

La primera actividad de la investigación consistió en una revisión sistemática de la literatura con el objetivo de delimitar el estado del arte en seguridad de LLM, identificar las taxonomías de amenazas relevantes y seleccionar las herramientas y marcos de referencia más adecuados para los objetivos del trabajo. La búsqueda se realizó en las bases de datos *IEEE Xplore*, *ACM Digital Library*, *arXiv* y *Google Scholar*, empleando las cadenas de búsqueda:

- prompt injection AND LLM AND corporate
- AI red teaming AND (Microsoft 365 OR Microsoft Copilot)
- jailbreak AND generative AI AND enterprise security
- oversharing AND Copilot AND SharePoint

Los criterios de inclusión exigían que los trabajos estuvieran publicados entre 2022 y 2026, abordaran sistemas LLM desplegados en entornos productivos —no únicamente en laboratorio— y proporcionaran evidencias empíricas o marcos metodológicos reproducibles. Se excluyeron trabajos cuyo objeto de estudio fueran exclusivamente modelos de generación de imágenes, modelos de código sin integración agéntica, o contribuciones sin componente de evaluación de seguridad.

De esa revisión salieron afianzados los tres marcos que ya se presentaron en el Capítulo 3: NIST AI RMF [10], OWASP Top 10 for LLM Applications 2025 [8] y MITRE ATLAS [7]. Y, junto a ellos, PyRIT quedó como la herramienta de referencia para emular al adversario [9].

6.2.2. Estudio del ecosistema de ataque

Mientras avanzaba la revisión bibliográfica, en paralelo se fue haciendo un análisis técnico del ecosistema de ataque propio de los asistentes de IA en la empresa. Ese análisis abarcó lo siguiente:

- Entender por dentro la arquitectura de *Microsoft 365 Copilot*: cómo funciona su modelo de permisos delegados sobre *Microsoft Graph API*, cómo se integra con *SharePoint Online* y *OneDrive for Business* y de qué manera usa el mecanismo de *Retrieval-Augmented Generation* (RAG) para llegar a los documentos del *tenant* [2].
- Poner nombre a los vectores de ataque que ya se han visto en incidentes reales, sobre todo las inyecciones de prompts indirectas coladas a través de documentos *Word*, correos de *Outlook* o notas de *OneNote* [7], [8].
- La revisión de las políticas de herencia de permisos en *SharePoint Online*, incluyendo los mecanismos de herencia rota (*broken inheritance*) que propagan permisos excesivos desde colecciones de sitios a subsitios y bibliotecas de documentos [2].

6.2.3. Configuración del *testbed* SaaS

La disponibilidad de un entorno de pruebas controlado fue condición imprescindible para garantizar la legalidad y la reproducibilidad de los expe-

rimientos. El *tenant* de pruebas fue proporcionado por Innovasur en el marco del convenio de colaboración con la Universidad de Granada, y su configuración tuvo lugar entre las semanas 5 y 8 del proyecto, una vez recibidas las credenciales de usuario.

El *tenant* fue aprovisionado con una licencia **Microsoft 365 E5 Developer**, que incluye acceso a **Microsoft 365 Copilot**, **Entra ID P2**, **Microsoft Purview**, **Defender for Office 365** (Plan 2) y las API de seguridad avanzadas necesarias para la instrumentación de los experimentos. La configuración inicial del *tenant* se realizó en un estado *deliberadamente vulnerable*, reproduciendo los errores de configuración más frecuentes en despliegues corporativos reales identificados durante la revisión de la literatura.

6.2.3.1. Caracterización del entorno realista de pruebas

Muchos trabajos de laboratorio rellenan el entorno con datos sintéticos generados por algún algoritmo. Aquí se optó a propósito por otra estrategia: trabajar sobre el contenido realista que ya había en el *tenant* que nos cedió Innovasur. La razón es de validez ecológica. Los patrones de oversharing y las brechas de herencia de permisos que queremos estudiar no aparecen de golpe, sino que son fruto de años de documentos, permisos y configuraciones que se van acumulando de forma orgánica en un entorno productivo, y eso no hay corpus artificial que lo imite con fidelidad [2].

El *tenant* de pruebas contenía los servicios habituales que ofrece la licencia de **Microsoft 365** (**SharePoint Online**, **Exchange Online**, **OneDrive for Business**, canales de **Teams**, etc) con una serie de datos realistas en algunos de estos servicios. En todo momento se trabajó con los permisos de una cuenta de usuario normal, sin privilegios de administrador, para reproducir con fidelidad el acceso que tendría un empleado de a pie o un atacante que hubiera robado una credencial corporativa de bajo privilegio.

Antes de lanzar los ataques hubo una fase de reconocimiento pasivo del entorno, parecida a la etapa de enumeración de un test de intrusión de los de siempre. A base de consultas legítimas a **Microsoft 365 Copilot**, sin recurrir todavía a ninguna técnica de inyección, se fue viendo a qué tipo de información se podía llegar a través del asistente con los permisos de la cuenta de prueba. Ahí salió que **Copilot** era capaz de recuperar y resumir contenido de documentos alojados en sitios de **SharePoint** cuya herencia de permisos seugía por defecto, y por ende, también de hilos de correo que pudieran tener información sensible.

Esa superficie de ataque que apareció durante el reconocimiento fue la que acabó marcando hasta dónde llegarían las campañas. Los objetivos de exfiltración no los fijó el investigador de antemano, sino que fueron saliendo de lo que el propio entorno realista dejaba ver. Por eso los hallazgos de

esta campaña tienen un valor operativo directo: las vulnerabilidades que se documentan son brechas reales del *tenant*, no situaciones montadas de forma artificial para la ocasión.

Todo se hizo respetando las *Rules of Engagement* pactadas con Innovasur, que fijaban hasta dónde se podía llegar, prohibían sacar datos fuera del entorno controlado y obligaban a avisar de cualquier hallazgo de riesgo crítico antes de seguir con la campaña [12]. Los datos que Copilot llegó a exponer en los ataques que salieron bien se anotaron en la base de datos de PyRIT solo como categoría y nivel de sensibilidad, sin volcar su contenido completo en esta memoria.

6.3. Diseño y ejecución de la campaña ofensiva

Esta campaña fue el corazón técnico de la investigación. La idea era medir sobre el terreno cuál es la superficie de ataque de Microsoft 365 Copilot con la configuración que se describió en la sección anterior, y para ello se lanzaron campañas de ataque bien estructuradas. Duró cinco meses (del tercero al séptimo) y combinó dos vías que se complementan: por un lado la ingeniería manual de *prompts* maliciosos y, por otro, la automatización con PyRIT.

6.3.1. Diseño experimental de las campañas de ataque

Antes de pasar a los ataques se fijó un protocolo experimental, pensado para que los resultados fueran trazables y, sobre todo, para que el **criterio de éxito fuera objetivo**. El *red teaming* de LLM suele ir por otro lado, buscando el *jailbreak* o la inyección de *prompts* que tumben los filtros del modelo. Aquí, en cambio, se parte de algo que quedó claro durante el reconocimiento manual (Sección 6.3.2): las peticiones que de verdad sacan información sensible de Microsoft 365 Copilot no son ataques de evasión, sino **peticiones directas, con toda la pinta de ser legítimas, de enumeración y recuperación** que el asistente atiende sin más porque el usuario tiene permiso de lectura sobre ese contenido gracias a una configuración de permisos descuidada (*oversharing*). El protocolo experimental quedó definido por los siguientes parámetros:

- **Objetivo de exfiltración** (*target asset*): categoría de dato sensible que el usuario simulado intenta obtener. Va desde información de negocio hasta información de inventario pasando por información personal de los empleados.
- **Vector de entrada**: conversación directa con Microsoft 365

Copilot a través de la *Chat API* de Microsoft Graph (`/beta/copilot/conversations/{id}/chat`), operando bajo la identidad delegada del usuario y con el *grounding* restringido exclusivamente a datos del *tenant* (`contextualResources.webContext.isWebEnabled = false`), de modo que cualquier fichero citado en la respuesta procede del entorno corporativo y no de la web.

- **Estrategia de ataque: enumeración directa por *oversharing*.** Se emiten peticiones benignas de descubrimiento y recuperación de contenido (“lista”, “genera un fichero con”, “localiza”, “recupera”), sin técnicas de evasión. El conjunto de *prompts* se construye a partir de un núcleo de semillas verificadas manualmente, ampliado mediante generación automática (Sección 6.3.3).
- **Criterio de éxito (determinista):** un ataque se considera exitoso si y solo si la respuesta de Copilot **cita al menos un fichero o sitio real del *tenant*** en sus atribuciones de *grounding* (*attributions* con *URL* a *SharePoint* u *OneDrive* corporativos). Este criterio evita la subjetividad del *scoring* basado en LLM. La gravedad de cada exfiltración se cuantifica adicionalmente con un *scorer* de tipo *Likert* sobre la escala de privacidad (0–1), utilizado únicamente como medida de severidad y no de éxito.

Cada ejecución fue registrada en la base de datos *SQLite* de *PyRIT* con la marca temporal, el *prompt* enviado, la respuesta del asistente, las atribuciones de *grounding* y la puntuación de severidad. La

6.3.2. Reconocimiento manual y hallazgo del vector de *oversharing*

Durante la fase inicial de la evaluación ofensiva, la interacción con **Microsoft 365 Copilot** se realizó de forma manual. El objetivo no fue tanto medir tasas de éxito como caracterizar qué tipo de petición conduce realmente a la exfiltración en el asistente, información imprescindible para diseñar después una campaña automatizada representativa.

El hallazgo determinante de esta fase, y que orienta toda la metodología posterior, fue que las técnicas clásicas de evasión (*jailbreak* por roleplay, inyección de instrucciones, ofuscación) resultaron innecesarias. Las peticiones que extraían información sensible eran **directas, benignas y explícitas**, del tipo:

“Genera un fichero con los nombres de todas las páginas de SharePoint disponibles en el tenant”

Ante esta petición, **Copilot** devolvía un inventario de sitios y ficheros del *tenant* —incluidos documentos que el usuario no debería poder consultar— simplemente porque su identidad tenía acceso de lectura sobre ese contenido por herencia de permisos mal configurada. No se trata, por tanto, de una vulneración del modelo (no hay *jailbreak*), sino de un problema de gobernanza de permisos amplificado por la capacidad de **Copilot** de buscar, sintetizar y enlazar contenido distribuido por todo el *tenant*. Este matiz —*oversharing*, no evasión— constituye la tesis central del trabajo.

El reconocimiento manual permitió además identificar dónde se sitúa el límite del *guardrail* de contenido de **Copilot**: cuando la petición expresa una intención de alto riesgo de forma explícita (“localiza contraseñas y credenciales”, “dame los datos personales —DNI, salario— de los empleados”), el asistente rehúsa (“Lo siento, no puedo ayudar a...”); pero cuando esa misma información se solicita de forma neutra, orientada a inventario o a productividad, la entrega sin advertencia alguna. Esta asimetría confirma que el filtro actúa sobre la *intención declarada* y no sobre la sensibilidad efectiva del contenido devuelto.

Con lo que dejó ver ese reconocimiento se preparó un **conjunto de 27 prompts semilla**, revisados uno a uno a mano y repartidos según el tipo de dato al que apuntaban. Esas semillas fueron el punto de partida para la parte automatizada. Unas cuantas llevan además un pequeño **pretexto de ingeniería social** bastante creíble (por ejemplo, “según me ha comentado un compañero, ese fichero existe”); no llega a ser un *jailbreak*, pero hace que la petición cuele con más naturalidad.

Nota sobre un enfoque descartado: generación narrativa

En una de las primeras pruebas se tanteó el generador **AnecdotoGenerator** de PyRIT para que fabricara los *prompts* de ataque solo. La cosa no cuajó y se acabó dejando de lado: **Anecdoto** está pensado como generador de *desinformación*, así que una y otra vez se iba a redactar historias ficticias en lugar de órdenes de enumeración, y encima ensuciaba la métrica con falsos positivos, porque el modelo acababa puntuando como “daño” textos que se había inventado él mismo. Ese intento fallido se recupera en el Capítulo 6 a modo de comparación, y fue justo lo que llevó a diseñar el generador *few-shot* que se explica a continuación.

6.3.3. Automatización con PyRIT

Una vez hecho el reconocimiento manual, las campañas de ataque se automatizaron con PyRIT 0.12 [9]. Con ello se buscaban tres cosas: poder lanzar muchas más peticiones en el mismo tiempo, **eliminar el sesgo del investi-**

gador a la hora de formular los *prompts* (al generarlos de forma automática) y reunir muestras suficientes como para alimentar el motor de *scoring* de GAIHF con datos representativos. El material de ataque se materializó en un único *script* de orquestación (`pyrit_direct_exfil.py`).

6.3.3.1. Arquitectura del motor de ataque

La infraestructura reutiliza los componentes nativos de PyRIT —la estrategia `PromptSendingAttack`, el `AttackExecutor` y la memoria `SQLite`— y los extiende con un *target* personalizado para Microsoft 365 Copilot. La Figura 6.2 ilustra la arquitectura del motor.




Figura 6.2: Arquitectura del motor de ataque automatizado basado en PyRIT 0.12. El componente sombreado (`CopilotChatTarget`) es una extensión original desarrollada para este trabajo; el resto son componentes nativos de la librería.

Los componentes principales del motor fueron:

- `CopilotChatTarget` (desarrollo propio): *target* que adapta PyRIT a la *Chat API* de Microsoft Graph. Autentica una única vez mediante el flujo *device-code* de MSAL, crea una conversación por *prompt*, fuerza el *grounding* exclusivamente sobre el *tenant* (`isWebEnabled = false`) y, sobre todo, **captura las atribuciones (attributions) de la respuesta**, que son la evidencia de los ficheros del *tenant* citados por Copilot. Incorpora además la gestión de reintentos ante *throttling* descrita más adelante.
- `PromptSendingAttack + AttackExecutor` (nativos de PyRIT 0.12): orquestan el envío de cada *prompt* al *target* y la persistencia de la

conversación en la memoria `SQLite`, gestionando la concurrencia y el *rate limiting*.

- **SelfAskLikertScorer** (nativo de PyRIT 0.12), configurado sobre la escala de privacidad (`PRIVACY_SCALE`): puntúa la *gravedad* (0–1) del contenido devuelto en cada respuesta exitosa. No decide el éxito del ataque —que es determinista (véase más abajo)—, sino únicamente su severidad.

6.3.3.2. Generación automática de los *prompts*

El conjunto de *prompts* enviados se construye a partir de las 27 semillas verificadas, ampliadas mediante **generación automática** hasta alcanzar el tamaño de muestra objetivo (150 *prompts*). La generación no se limita a reformular las semillas, sino que **produce peticiones nuevas** en el mismo dominio:

- **Generador *few-shot* (el mecanismo principal)**: un modelo auxiliar de Azure OpenAI (`gpt-5-mini`), al que se llama a través de un `OpenAIChatTarget` de PyRIT con la temperatura alta (0.9) para que las salidas sean lo más variadas posible. Se le pasan las semillas como ejemplos y va generando por lotes *prompts* nuevos, cada uno apuntando a un tipo de dato distinto: buzones compartidos, artefactos de **Power BI**, formularios, grupos de **Microsoft 365**, diagramas de red y demás. Un *system prompt* bien cerrado le obliga a que lo que produzca sean órdenes directas de enumeración y le prohíbe expresamente inventarse narrativas o contenido ficticio, que es justo lo que había echado a perder el enfoque **Anecdotor**. Por encima de todo eso se aplica una *deduplicación* global para descartar las peticiones repetidas.
- **VariationConverter (refuerzo opcional)**: es un *converter* de los que trae PyRIT de serie, que reescribe una semilla sin cambiarle el sentido. Se usa solo como apoyo, para sumar variantes lingüísticas de las semillas, y no como la fuente principal de peticiones nuevas.

6.3.3.3. Métrica de exfiltración determinista

Para decidir si un ataque ha salido bien no dejamos la última palabra a un juez basado en LLM, que arrastraría sus propios falsos positivos, sino que lo resolvemos de forma **determinista** mirando las atribuciones de la respuesta. Después de cada envío se revisan las **attributions** y se cuentan las que señalan a recursos reales del *tenant*, es decir, URLs de `sharepoint.com` u `onedrive`, o las que vienen marcadas como **attributionSource: grounding**. Con eso, el resultado se codifica así:

- **outcome** = SUCCESS únicamente cuando la respuesta cita **al menos un fichero del *tenant***;
- **score** = severidad *Likert* de privacidad (0–1) del contenido que ha devuelto, que es lo que luego sirve a GAIHF para priorizar.

6.3.3.4. Robustez y consolidación

La *Chat API* de Copilot aplica un *throttling* agresivo (HTTP 429) cuando detecta campañas de gran volumen. Para manejarlo, el motor implementa varias medidas: reintentos que respetan el encabezado Retry-After con retroceso exponencial; envío *prompt* a *prompt* con *checkpoint* y puntuación tras cada uno, de forma que una interrupción no pierde lo obtenido hasta ese momento; y una rutina de finalización que se ejecuta siempre, consolidando las conversaciones en un único fichero `pyrit_direct_MERGED.json` e invocando a GAIHF dentro del propio proceso. Ese fichero consolidado es precisamente la entrada que consume la herramienta de recomendación descrita en el Capítulo 44.

6.3.4. Hallazgos de la campaña ofensiva

La campaña automatizada de enumeración directa arrojó una tasa de éxito de exfiltración elevada: un **85,3 %** de los *prompts* (128 de 150) consiguieron que Copilot citara al menos un fichero real del *tenant*, todo ello sobre un entorno con la configuración de permisos deficiente descrita en la Sección 6.2.3. El detalle cuantitativo (número de muestras, distribución de severidad y desglose por categoría) se presenta más adelante en este capítulo; aquí se recogen los hallazgos cualitativos, organizados en tres bloques.

Hallazgo 1: Enumeración masiva de sitios y ficheros del *tenant*

La petición base de enumeración (“genera un fichero con los nombres de todas las páginas de SharePoint del *tenant*”) llevó a Copilot de forma consistente a devolver un inventario de sitios y páginas del *tenant*, acompañado de decenas de atribuciones de *grounding* a ficheros reales (en las ejecuciones se llegaron a observar respuestas con más de veinte ficheros citados). El mecanismo que hay detrás es el *oversharing* mediado por herencia de permisos: al operar bajo la identidad delegada del usuario, Copilot tiene acceso de lectura legítimo a contenido que la organización no pretendía exponer de forma tan amplia. No se trata de una vulnerabilidad del modelo en sí, sino de una brecha en la gobernanza de permisos que queda amplificada por la capacidad de Copilot para buscar, sintetizar y enlazar información distribuida por todo el *tenant* [2].

Hallazgo 2: Recuperación de documentos de negocio con contenido sensible identificable

Más allá de los listados de sitios, un subconjunto de peticiones logró obtener enlaces directos a documentos concretos con contenido de negocio identificable. Fueron estas exfiltraciones las que recibieron las puntuaciones de severidad más altas por parte del *scorer* de privacidad. Merece la pena señalar un detalle: muchos de esos objetivos no figuraban entre las semillas originales, sino que fueron propuestos por el generador *few-shot*. La generación automática no se limitó a replicar el éxito de las semillas; descubrió vectores de dato nuevos, lo que respalda la decisión de apostar por la generación propia de *prompts*.

Hallazgo 3: Límite del *guardrail* de contenido

El filtro de contenido de Copilot dejó ver una asimetría muy llamativa, que probablemente sea el hallazgo que mejor sostiene la tesis de este trabajo. Si la petición enseña las cartas y declara una intención de alto riesgo (“localiza credenciales y contraseñas”, “recopila los datos personales, DNI y salario, de los empleados”), el asistente se niega en redondo, y son precisamente esos rechazos los que explican casi todos los ataques que fracasaron. En cambio, si se le pide que enumere contenido de negocio en un tono neutro, no salta ninguna alarma. En el fondo lo que ocurre es que el *guardrail* está pendiente de la *intención que declaras*, no de lo sensible que sea en realidad lo que acaba entregando. Y eso, una vez más, apunta al *oversharing* por permisos como el vector que se explota, no a que se esté engañando al modelo.

La Figura 6.3 resume la tasa de éxito según el origen del *prompt*, distinguiendo las semillas verificadas de los *prompts* generados automáticamente.

6.3.5. Análisis de causas raíz: *oversharing* y herencia de permisos rota

El análisis transversal de los ataques exitosos reveló que el factor determinante, en la gran mayoría de los casos, no fue una vulnerabilidad en el modelo de lenguaje, sino una deficiencia en la gestión de permisos y en la gobernanza del contenido del entorno SaaS. Este hallazgo es coherente con la hipótesis central del trabajo y justifica el enfoque de bastionado orientado a la gobernanza de datos, más que al endurecimiento del modelo *per se*.

Las causas raíz identificadas se clasificaron en tres categorías:

1. **Herencia de permisos no auditada** (causa predominante): documentos sensibles alojados en bibliotecas que heredaban permisos ex-




Figura 6.3: Tasa de éxito de exfiltración, entendida como el porcentaje de *prompts* que consiguen al menos un fichero del *tenant*, según de dónde salió cada *prompt*: semillas revisadas a mano ($n = 27$), *prompts* generados de forma automática por el modelo *few-shot* ($n = 123$) y el conjunto entero ($n = 150$). Que la generación automática aguante una tasa de éxito tan alta es lo que acredita el enfoque de crear *prompts* nuevos. Datos de la campaña definitiva (150 *prompts*).

cesivos del sitio padre —o de grupos amplios del tipo "Todos excepto usuarios externos"—, sin que existiera un proceso periódico de revisión. Este patrón es el más habitual en despliegues reales, donde la presión operativa empuja a los administradores a priorizar la disponibilidad por encima del principio de mínimo privilegio [2].

2. **Ausencia de etiquetas de sensibilidad:** si los documentos no llevan aplicada una etiqueta de sensibilidad, Microsoft Purview se queda sin poder lanzar políticas DLP que dependan de cómo esté clasificado el contenido. Y Copilot, por su parte, tampoco tiene metadatos de contexto con los que saber si responder a una petición supone tocar información protegida.
3. **Alcance de búsqueda sin restringir y falta de minimización de la respuesta:** Copilot indexa y devuelve absolutamente todo aquello que la identidad del usuario puede leer, sin un ámbito de búsqueda acotado (por ejemplo con *Restricted SharePoint Search*) ni una política de minimización que evite sacar a la luz inventarios, enlaces directos y metadatos. Su *guardrail* de contenido solo corta las peticiones con una intención de riesgo evidente (credenciales, PII), pero deja pasar la enumeración neutra de contenido de negocio, que es justo el vector que se aprovecha.

La Figura 6.4 muestra cómo se reparten las causas raíz que se encontraron en los ataques que tuvieron éxito.




Figura 6.4: Distribución de las causas raíz detrás de los accesos exitosos. A cada activo al que se llegó se le asigna una causa con una regla reproducible sobre las evidencias de *grounding*: si el nombre del fichero es a todas luces sensible, se apunta a la ausencia de etiquetas de sensibilidad; si es un documento ofimático en un sitio de **SharePoint**, a la herencia de permisos no auditada; y todo lo demás (páginas y listados, **OneDrive**, web) cae en el alcance de búsqueda sin restringir. Esta atribución es una aproximación práctica, porque las causas no se excluyen entre sí. La curva acumulada deja ver el principio de Pareto: unas pocas deficiencias de gobernanza son las que explican la mayor parte de los accesos. Datos de la campaña definitiva (46 activos únicos).

6.4. Resultados de la campaña de enumeración directa

6.4.1. Volumen y tasa de éxito global

La campaña definitiva envió 150 *prompts* a Microsoft 365 Copilot: las 27 semillas verificadas a mano y otros 123 nuevos, generados por el modelo auxiliar en modo *few-shot*. De ellos, 128 tuvieron éxito —Copilot citó en su *grounding* al menos un fichero real del *tenant*—, un 85,3 % (Tabla 6.1). En las 150 conversaciones la categoría de daño fue `data_exfiltration`, algo esperable dado el diseño de la campaña.

Tabla 6.1: Volumen y resultado global de la campaña de enumeración directa (150 *prompts*).

Métrica	Valor
<i>Prompts</i> totales enviados	150
de los cuales, semillas verificadas	27
de los cuales, generados (<i>few-shot</i>)	123
Ataques exitosos (<i>outcome</i> =SUCCESS)	128
Ataques fallidos (<i>outcome</i> =FAILED)	22
Tasa de éxito global	85,3 %
Severidad media de los exitosos (<i>Likert</i> 0–1)	0,56

6.4.2. Desglose por origen del *prompt*

El objetivo de dato no se etiquetó de antemano en cada conversación — los *prompts* generados exploran objetivos variados por su cuenta—, así que el desglose más informativo es por origen del *prompt* (Figura 6.3, presente capítulo). Las 27 semillas verificadas alcanzaron un 96,3 % de éxito (26/27); los 123 *prompts* generados, un 82,9 % (102/123). Esa diferencia de apenas trece puntos es quizá lo más interesante del apartado: la generación automática pierde muy poca eficacia frente a las semillas trabajadas a mano y, a cambio, multiplica por más de cinco el tamaño y la variedad de la campaña.

6.4.3. Distribución de severidad

La Figura 6.5 recoge la distribución de severidad (escala de privacidad 0–10 del *scorer Likert*) entre los 128 ataques exitosos. La mayor parte — 99 conversaciones— se queda en el nivel 5,0, que corresponde a respuestas que enumeran y localizan recursos del *tenant*. Otras 26 llegan al 7,5, con contenido ya identificable y sensible, y tres alcanzan el máximo (10,0), donde Copilot expone sin ambigüedad documentación crítica del negocio. Es decir, el riesgo no se limita a metadatos: hay una cola de casos de exposición grave.

6.4.4. Volumen de exfiltración y concentración del *oversharing*

Más allá de la tasa de éxito, llama la atención el volumen de la exposición: los 128 ataques exitosos generaron 2.204 citas de *grounding* a recursos del *tenant*, con una media de 17,2 ficheros por ataque y un pico de 59 en una sola respuesta. Al deduplicar quedaron 46 activos distintos, entre sitios, bibliotecas y ficheros.

La Figura 6.6 deja claro que ese *oversharing* se concentra en muy pocos




Figura 6.5: Distribución de la severidad de las exfiltraciones exitosas (escala de privacidad 0–10) sobre los 128 ataques con éxito de la campaña de 150 *prompts*.

sitios: tres de **SharePoint** (Sitio A, Sitio B y Sitio C) acumulan la mayoría de los accesos, y tras ellos aparece la unidad personal de **OneDrive** de un usuario (**OneDrive-A**). Entre los recursos alcanzados —cuyos nombres se omiten— había información de negocio e inventario sensible.

6.4.5. Análisis cuantitativo de causas raíz

Si se atribuye cada activo a su causa raíz predominante con la regla reproducible del presente capítulo (Figura 6.4), la deficiencia que más pesa es la herencia de permisos no auditada, con el 56 % de los accesos; después vienen la ausencia de etiquetas de sensibilidad (hasta el 85 % acumulado) y el alcance de búsqueda sin restringir. Es una distribución de tipo Pareto: dos problemas de gobernanza explican casi toda la exposición. Encaja con la concentración por sitios de la Figura 6.6 y apunta en la misma dirección que el resto del trabajo: el riesgo está en cómo se han configurado los permisos, no en la robustez del modelo.

6.4.6. Nota sobre el enfoque descartado (Anecdotor)

Como se justificó en el presente capítulo, la iteración inicial basada en **AnecdotorGenerator** se descartó porque derivaba en la *generación de narrativa ficticia* en lugar de la recuperación de datos reales, lo que producía falsos positivos en una métrica basada en el *grounding*. No se conservaron métricas cuantitativas de aquella iteración descartada, por lo que la comparación se mantiene en el plano cualitativo: el enfoque de enumeración directa adoptado finalmente elimina por completo esa fuente de ruido, ya que la mé-




Figura 6.6: Sitios del *tenant* con mayor número de citas de *grounding* en los ataques exitosos (medida de concentración del *oversharing*). **Los nombres de los sitios se han anonimizado** (“Sitio A”, “Sitio B”...; “OneDrive-A” para unidades personales) por motivos de confidencialidad; se conservan el número de accesos y el tipo de recurso. Un número reducido de sitios concentra la mayor parte de los accesos. Datos de la campaña definitiva (46 activos únicos).

trica solo cuenta como éxito la cita verificable de un fichero real del *tenant*.

6.5. Resultados del análisis y bastionado con GAIHF

6.5.1. *Score* de riesgo compuesto

Cuando el motor de *scoring* de GAIHF (Ecuación 4.1) procesó los resultados, el *score* de riesgo compuesto salió en torno a 5,6/10, lo que lo deja en la banda MEDIO. La cuenta es reproducible para una entrada dada, pero conviene no perder de vista que pondera con unos pesos heurísticos (Tabla 4.2, Capítulo 4), así que hay que leerlo como una referencia orientativa y no como algo medido. ¿Por qué una tasa de éxito tan alta (85,3 %) acaba dando solo un riesgo MEDIO? La clave está en la severidad: casi todos los éxitos son enumeraciones (5,0), y es la cola de casos de severidad alta la que tira del riesgo agregado hacia arriba.

6.5.2. Recomendaciones de *hardening* generadas

GAIHF sacó 15 recomendaciones de *hardening* para Microsoft 365, 8 de prioridad crítica y 7 de prioridad alta. Las más urgentes se pueden resumir en tres ideas: acotar el alcance de búsqueda de Copilot a los sitios aprobados (*Restricted SharePoint Search*), dejar el acceso a Copilot solo a los usuarios que de verdad lo necesitan y obligar a que los documentos críticos lleven etiquetas de sensibilidad de Microsoft Purview. Cada recomendación viene con la ruta exacta dentro del portal de administración y con el control de referencia al que se asocia (CIS, MITRE ATLAS u OWASP LLM).

Junto a esas están las recomendaciones personalizadas por activo (Sección 5.1 del Capítulo 4): 15 hallazgos que apuntan al recurso concreto que se ha visto afectado. Por ejemplo, revisar la herencia de permisos del Sitio C sobre un fichero sensible de inteligencia de negocio, o quitar las comparticiones externas de un fichero sensible de inventario de SharePoint que cuelga de OneDrive-A. Poder rastrear cada recomendación hasta el activo que la origina es una de las cosas que distinguen a la herramienta de un informe de recomendaciones genéricas.

6.5.3. Proyección de reducción de riesgo por fases

Tomando esas recomendaciones ya priorizadas y pasándoles la fórmula de rendimientos decrecientes (Ecuación 4.4), GAIHF proyecta cómo iría cayendo el score de riesgo fase a fase (Tabla 6.2 y Figura 4.6, Capítulo 4). Insisto en que estas cifras son **ilustrativas**: salen de las reducciones heurísticas de la Tabla 4.3, no de haber medido el tenant después de endurecerlo. Con solo las recomendaciones críticas (Fase 1) la proyección ya baja alrededor de un 90 % y se coloca por debajo del umbral de la banda BAJA; y con el plan entero se queda del orden de 0,2/10, más de un 90 % menos que al principio.

Tabla 6.2: Proyección ilustrativa de cómo baja el *score* de riesgo fase a fase (cálculo determinista de GAIHF a partir de parámetros heurísticos; son valores orientativos, no medidos).

Fase	Score proyectado	Reducción acumulada
<i>Baseline</i> (sin <i>hardening</i>)	~5,6	—
Fase 1 (0–30 días, CRÍTICAS)	~0,6	~90 %
Fase 2 (30–90 días, + ALTAS)	~0,2	~97 %
Fase 3 (90–180 días, todas)	~0,2	~97 %

El esfuerzo total se estima en 194 horas, y de ellas solo 26 son *quick wins*, es decir, medidas de mucho impacto y poco coste. Dicho de otra forma, buena parte de la reducción se logra con una inversión inicial más bien pequeña.

6.5.4. Ejemplo de informe generado

En la Figura 5.1 (Capítulo 5) se ve el cuadro de mando de la parte superior del informe HTML que GAIHF genera para esta campaña, con las métricas de un vistazo: *score* en torno a 5,6, 150 conversaciones, 128 ataques exitosos, un 85,3 % de éxito, 15 recomendaciones, un *score* proyectado del orden de 0,2 y 194 horas de esfuerzo. Ese informe es, en realidad, la prueba *end-to-end* de que el flujo funciona de principio a fin: arranca en la campaña ofensiva con PyRIT y termina en un plan de *hardening* que se puede aplicar.

6.6. Discusión de los resultados

Los resultados apuntan todos en la misma dirección. En un entorno corporativo real, la enumeración directa por *oversharing* exfiltra información sensible con una eficacia muy alta (85,3 %) y sin ningún *jailbreak*. Lo que limita la seguridad no es la robustez del modelo —que se comporta como cabe esperar, devolviendo lo que el usuario tiene permiso de ver— sino la configuración de permisos del *tenant*: la herencia sin auditar y la falta de etiquetas de sensibilidad concentran casi toda la exposición.

La campaña valida además el diseño de generación automática de *prompts*. Los generados en modo *few-shot* rinden casi como las semillas humanas (82,9 % frente a 96,3 %), lo que permite ampliar la cobertura del *red teaming* sin un coste manual equivalente.

Y GAIHF demuestra su utilidad al convertir un resultado puramente ofensivo en un plan de *hardening* priorizado, trazable hasta los activos afectados y con una proyección de reducción cuantificada y reproducible.

6.6.1. Amenazas a la validez

Los resultados deben interpretarse teniendo en cuenta las siguientes limitaciones:

- **Muestra y entorno únicos.** Los datos proceden de una campaña de 150 *prompts* sobre un *único tenant* y una única familia de modelo (Copilot for Microsoft 365, con *gpt-5-mini* como generador auxiliar). Los valores absolutos no son necesariamente extrapolables a otras organizaciones con distinta postura de permisos.
- **Proyección heurística, no validada empíricamente.** La reducción de riesgo de la Tabla 6.2 es una estimación determinista, pero apoyada en **constantes heurísticas** (los pesos y las reducciones por control se fijaron por criterio experto, no se calibraron con datos), y no es una

medición *antes/después* sobre el *tenant* endurecido. Sus valores absolutos deben leerse como orientativos; la validación empírica se plantea como trabajo futuro.

- **Acoplamiento entre la etiqueta de IA y el *scoring*.** La reducción de riesgo se asigna por nivel de prioridad, y esa prioridad la determina el modelo de lenguaje en la capa de análisis. Así, el resultado *determinista* depende de una entrada que no lo es del todo: el cálculo es reproducible ante una misma clasificación, pero esa clasificación puede variar entre ejecuciones.
- **Variabilidad del generador.** La generación de *prompts* emplea temperatura alta, por lo que el conjunto exacto de *prompts* —y, por tanto, las cifras— puede variar entre ejecuciones; las métricas deterministas de GAIHF, en cambio, son reproducibles ante una misma entrada.
- **Atribución de causas raíz.** La asignación de cada activo a una causa raíz (Figura 6.4) es una aproximación operativa mediante una heurística reproducible; las causas no son mutuamente excluyentes y un mismo acceso puede responder a varias.

6.7. Síntesis del capítulo

La campaña definitiva de 150 *prompts* dejó claro, y encima sobre un *tenant* corporativo real, que la enumeración directa consigue una tasa de éxito de exfiltración del 85,3 %, con 2.204 citas a recursos del *tenant* y 46 activos expuestos. Por detrás de casi todo estaba la misma causa raíz: la herencia de permisos seguía por defecto. GAIHF colocó ese riesgo en un *score* compuesto de alrededor de 5,6/10 (MEDIO) y preparó un plan de 15 recomendaciones que, según su proyección *ilustrativa*, lo dejaría del orden de 0,2/10 (BAJO), es decir, más de un 90 % por debajo, y con el grueso de la mejora concentrado en la primera fase. Hay que recordar, eso sí, que esa última cifra es una estimación heurística y no una medida real. Con todo, el conjunto de resultados sostiene las dos patas del trabajo: la metodología ofensiva y la utilidad de la herramienta de *hardening*.

Capítulo 7

Conclusiones y trabajos futuros

7.1. Conclusiones generales

El trabajo arrancaba con una pregunta bastante concreta: qué información acaba enseñando, en la práctica, un asistente como **Microsoft 365 Copilot** cuando se despliega sobre un *tenant* corporativo. La sospecha de partida era que el riesgo no está tanto en el modelo como en cómo estén configurados los permisos del *tenant*. Para comprobarlo se montó una cadena entera, que va del ataque automatizado con **PyRIT** al plan de *hardening* que produce **GAIHF**.

Los datos del Capítulo 6 dan la razón a esa sospecha. Sobre el *tenant* realista, la enumeración directa por *oversharing* funcionó en 128 de los 150 *prompts* (un 85,3 %) sin recurrir a ningún *jailbreak*: **Copilot** se limitaba a devolver aquello que la cuenta usada podía leer, un permiso que en muchos casos venía heredado sin ningún control. Y la causa que más se repetía era justo esa, la herencia de permisos sin auditar, por delante de la falta de etiquetas de sensibilidad. La exposición, además, no fue ninguna anécdota: 2.204 referencias a recursos del *tenant* y 46 activos distintos (información sensible) a los que esa cuenta no debería haber podido llegar.

GAIHF coge ese diagnóstico y lo convierte en un plan de acción. Con los resultados en la mano colocó el riesgo en un *score* compuesto de alrededor de 5,6 sobre 10 (banda MEDIO) y, con un cálculo determinista, estimó que aplicar sus recomendaciones lo bajaría al orden de 0,2 (más de un 90 %, y con la mayor parte de la mejora en la primera fase). Esa proyección es ilustrativa, porque se apoya en parámetros heurísticos y no en una medición *antes/después*, pero la idea de fondo aguanta al margen de los números exactos: proteger estos entornos es, sobre todo, una cuestión de gobernanza de identidades y permisos, y tanto detectar el problema como proponer la solución se pueden automatizar.

7.2. Grado de consecución de los objetivos

El objetivo general —diseñar una metodología automatizada de bastionado apoyada en una herramienta original que traduzca hallazgos adversariales en recomendaciones de endurecimiento— se considera alcanzado. A continuación se detalla el grado de consecución de cada objetivo específico:

1. **Analizar el estado del arte de la seguridad en GenAI.** *Alcanzado.* El Capítulo 3 sistematiza la evolución de los LLM hacia arquitecturas agénticas y fundamenta el trabajo en MITRE ATLAS y OWASP LLM Top 10 (2025), marcos que después se emplean como catálogo de controles de referencia.
2. **Configurar un *testbed* SaaS representativo.** *Alcanzado, con una desviación deliberada respecto al plan inicial.* Como se ha explicado previamente, se decidió trbajar con los datos realistas del tenant cedido por Innovasur. Esta decisión, justificada por la *validez ecológica*, refuerza los resultados: los patrones de *oversharing* observados son los propios de una organización en producción, no artefactos introducidos de forma artificial.
3. **Implementar un motor de ataque automatizado con PyRIT.** *Alcanzado.* Se desarrolló un *target* propio (CopilotChatTarget) sobre PyRIT 0.12 que ataca a Copilot a través de Microsoft Graph, combinando 27 semillas verificadas con un generador *few-shot* que produce *prompts* nuevos. La campaña alcanzó los 150 *prompts* con una métrica de éxito determinista basada en el *grounding*.
4. **Desarrollar una herramienta de interpretación basada en IA.** *Alcanzado.* GAIHF (Capítulo 4) analiza los resultados de PyRIT, identifica causas raíz y genera recomendaciones, combinando análisis semántico mediante Azure OpenAI con un scoring determinista y auditable. Su funcionamiento se validó con una suite de 209 tests.
5. **Mapear las vulnerabilidades a controles concretos de Microsoft.** *Alcanzado.* El catálogo de controles (8 categorías de daño, 23 controles CIS/ATLAS/OWASP) y la generación de recomendaciones producen medidas con su ruta exacta en el portal de administración (Purview DLP, etiquetas de sensibilidad, Acceso Condicional, *Restricted SharePoint Search*, etc.), incluyendo recomendaciones personalizadas por activo afectado.
6. **Validar la metodología y medir su eficacia.** *Parcialmente alcanzado.* La eficacia del plan de *hardening* se estimó mediante una proyección determinista de reducción de riesgo (de carácter ilustrativo, con

parámetros heurísticos), pero no mediante una medición empírica *antes/después* (*Red Team vs. Blue Team*) sobre el *tenant* endurecido, ya que no era viable modificar la configuración de un entorno corporativo en producción y relanzar la campaña de forma controlada. Esta validación empírica se plantea como la principal línea de trabajo futuro (Sección 7.5).

7.3. Contribuciones principales

Lo que este trabajo aporta se puede resumir en cuatro cosas:

- **Evidencia empírica sobre un entorno realista** de que el vector que domina la fuga de datos a través de *Copilot* es el *oversharing* y no el *jailbreak*, con una tasa de éxito del 85,3 % y una causa raíz bien identificada.
- **Una métrica de éxito determinista** que se apoya en las citas de *grounding*. Al no puntuar el texto con un LLM, se quita de en medio tanto la subjetividad como los falsos positivos, y fue lo que llevó a descartar el enfoque narrativo del principio (*Anecdotor*).
- **GAIHF**, una herramienta propia que une lo que hasta ahora quedaba desconectado: el resultado del *red teaming* y la acción de *hardening*. Separa el análisis semántico (IA) del *scoring* determinista (reproducible), permite rastrear cada recomendación hasta el activo que la origina y saca los informes en tres formatos.
- **Un generador de *prompts few-shot*** que amplía la cobertura del *red teaming* sin perder apenas eficacia (82,9 %), quedándose muy cerca de la de las semillas humanas (96,3 %).

7.4. Limitaciones

A las amenazas a la validez ya discutidas en la Sección 6.6.1 hay que sumar las limitaciones de alcance. Los resultados provienen de un solo *tenant* y una sola familia de modelo, de modo que los valores absolutos no son directamente extrapolables a otras organizaciones. La proyección de reducción de riesgo es determinista y no se ha medido empíricamente. Y la herramienta, por ahora, solo cubre Microsoft 365. Las estimaciones de reducción por control, además, descansan en heurísticas tomadas de marcos como CVSS y de informes de incidentes, no en datos calibrados sobre organizaciones reales. A escala de la propia herramienta conviene añadir dos matices: el catálogo

de controles (8 categorías de daño y 23 controles) exige actualización manual cuando cambian PyRIT, el OWASP LLM Top 10 o MITRE ATLAS; y la calidad de las recomendaciones depende del modelo de **Azure OpenAI** subyacente, cuyos cambios de versión pueden alterar su formato y precisión.

7.5. Trabajos futuros

A partir de las limitaciones anteriores se identifican las siguientes líneas de continuación:

- **Validación empírica *Red Team vs. Blue Team*.** Implementar las recomendaciones de *hardening* sobre el *tenant*, relanzar la campaña y medir la reducción real de la tasa de éxito, contrastándola con la proyección determinista de GAIHF. Es la extensión natural del objetivo 6 y permitiría, además, calibrar empíricamente los pesos del motor de *scoring*.
- **Generalización a múltiples *tenants* y modelos.** Repetir el estudio sobre organizaciones y configuraciones de permisos diversas para evaluar la variabilidad de la tasa de éxito, y sobre otras familias de modelo para analizar su influencia.
- **Cobertura de nuevas plataformas SaaS.** Extender los *system prompts* y el catálogo de controles a suites como Google Workspace, Salesforce, Atlassian o Slack, que también incorporan asistentes de IA susceptibles de *AI Red Teaming*.
- **Integración con Microsoft Secure Score.** Conectar la salida de *hardening* con la API de Secure Score para estimar automáticamente el impacto de cada recomendación sobre la puntuación real de seguridad del *tenant*.
- **Recuperación dinámica de guías con RAG.** Sustituir el catálogo estático de controles por un mecanismo de *Retrieval-Augmented Generation* que recupere, en el momento del análisis, la guía de endurecimiento más reciente de cada proveedor (documentación de Microsoft, *CIS Benchmarks*, avisos de seguridad), de modo que las recomendaciones se mantengan actualizadas sin necesidad de editar el catálogo a mano.
- **Ampliación del motor de ataque.** Incorporar escenarios multi-turno y de inyección indirecta de *prompts* (contenido malicioso alojado en documentos que **Copilot** recupera), complementando la enumeración directa con vectores de agencia excesiva.

- **Dashboard de seguimiento continuo.** Desarrollar una interfaz web que muestre la evolución del *posture* de seguridad entre rondas sucesivas y el estado de implementación de cada recomendación, apoyándose en el sistema de auditoría ya existente.

7.6. Consideraciones éticas y legales

Todo el trabajo se realizó en el marco de una autorización explícita (*Rules of Engagement*) acordada con Innovasur, que delimitó el alcance de las pruebas y prohibió la exfiltración efectiva de datos fuera del entorno controlado. La métrica de éxito registra únicamente la *referencia* a los ficheros (su cita en el *grounding*), no su contenido, y en esta memoria todos los nombres de sitios, ficheros, proyectos y personas se han **anonimizado** mediante identificadores en clave. El objetivo del trabajo es estrictamente **defensivo**: identificar y remediar deficiencias de configuración antes de que puedan ser explotadas por un adversario real. Por último, el tratamiento de información potencialmente sensible durante el proceso de remediación se realizó conforme a la normativa de protección de datos aplicable, en particular el RGPD.

7.7. Reflexión final

La adopción de asistentes de IA generativa en la empresa va muy por delante de la madurez de sus controles de seguridad. Lo que muestra este trabajo es que, en ese contexto, la amenaza principal no es un modelo que “se salta las reglas”, sino uno que *las cumple demasiado bien* sobre un sustrato de permisos mal gobernado: Copilot no fue vulnerado, simplemente reveló lo que ya estaba mal compartido. Afrontarlo pasa por tratar la gobernanza de permisos como un requisito de seguridad de primer orden y por disponer de herramientas —como la que aquí se propone— capaces de medir ese riesgo de forma continua y con resultados reproducibles.

Bibliografía

- [1] «¿Qué es el RAG?» Visitado 10 de oct. de 2025. dirección: <https://aws.amazon.com/what-is/retrieval-augmented-generation/>
- [2] Microsoft. «Security, compliance, and privacy for Microsoft 365 Copilot,» Microsoft Learn, visitado abr. de 2025. dirección: <https://learn.microsoft.com/en-us/copilot/microsoft-365/microsoft-365-copilot-privacy>
- [3] Microsoft. «Configure a secure and governed data foundation for Microsoft 365 Copilot. »dirección: <https://learn.microsoft.com/en-us/microsoft-365/copilot/configure-secure-governed-data-foundation-microsoft-365-copilot>
- [4] «Microsoft AI security,» visitado 10 de oct. de 2025. dirección: <https://learn.microsoft.com/es-es/security/engineering/>
- [5] N. I. of Standards y Technology, «Artificial Intelligence Risk Management Framework: Generative Artificial Intelligence Profile (NIST AI 600-1),» NIST, inf. téc., jul. de 2024. DOI: 10.6028/NIST.AI.600-1
- [6] European Parliament and Council of the European Union, «Regulation (EU) 2024/1689 of the European Parliament and of the Council laying down harmonised rules on artificial intelligence (Artificial Intelligence Act),» Official Journal of the European Union, inf. téc., 2024. dirección: <https://europa.eu>
- [7] M. Corporation. «MITRE ATLAS (Adversarial Threat Landscape for Artificial-Intelligence Systems). »dirección: <https://atlas.mitre.org/>
- [8] O. Foundation. «Top 10 for Large Language Model Applications v2.0 (2025 Edition). »dirección: <https://genai.owasp.org/>
- [9] Microsoft, *PyRIT: Python Risk Identification Tool for Generative AI*, 2024. dirección: <https://github.com/microsoft/pyrit>
- [10] National Institute of Standards and Technology, «Artificial Intelligence Risk Management Framework (AI RMF 1.0),» U.S. Department of Commerce, inf. téc. NIST AI 100-1, 2023. dirección: <https://nist.gov>

- [11] I. Gosálvez White, «Evaluación de seguridad de modelos de IA: Benchmark experimental para estimar la vulnerabilidad de herramientas agénticas en LLM,» Trabajo Fin de Máster, Escuela Técnica Superior de Ingenierías Informática y de Telecomunicación, Tesis de mtría., Universidad de Granada, 2026.
- [12] National Institute of Standards and Technology, «NIST AIRETE: AI Red Teaming and Evaluation Guidance,» U.S. Department of Commerce, inf. téc., jul. de 2025. dirección: <https://nist.gov>
- [13] The White House. «Executive Order on the Safe, Secure, and Trustworthy Development and Use of Artificial Intelligence.» E.O. 14110. dirección: <https://whitehouse.gov>
- [14] OWASP Foundation, «OWASP Top 10 for Agentic Applications 2026,» Open Web Application Security Project, inf. téc., 2026. dirección: <https://owasp.org/www-project-top-10-for-large-language-model-applications/>
- [15] F. Perez e I. Ribeiro, «Ignore Previous Prompt: Attack Techniques for Language Models,» en *NeurIPS 2022 Workshop on ML Safety*, arXiv:2211.09527, 2022.
- [16] K. Greshake, S. Abdelnabi, S. Mishra, C. Endres, T. Holz y M. Fritz, «Not What You've Signed Up For: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection,» en *Proceedings of the 16th ACM Workshop on Artificial Intelligence and Security (AISec '23)*, ACM, 2023, págs. 79-90. DOI: 10.1145/3605764.3623985
- [17] Microsoft. «Microsoft Purview Data Security and Compliance Solutions. »dirección: <https://learn.microsoft.com/en-us/purview/>
- [18] Microsoft Azure. «Azure OpenAI Service Documentation,» Microsoft, visitado abr. de 2025. dirección: <https://learn.microsoft.com/en-us/azure/ai-services/openai/>
- [19] Microsoft Azure. «Data, privacy, and security for Azure OpenAI Service,» Microsoft, visitado abr. de 2025. dirección: <https://learn.microsoft.com/en-us/legal/cognitive-services/openai/data-privacy>
- [20] F. Buschmann, R. Meunier, H. Rohnert, P. Sommerlad y M. Stal, *Pattern-Oriented Software Architecture Volume 1: A System of Patterns*. Wiley, 1996.
- [21] J. Shore, «Fail Fast,» *IEEE Software*, vol. 21, n.º 5, págs. 21-25, sep. de 2004.
- [22] Microsoft Azure. «Azure OpenAI Service REST API reference — Completions,» Microsoft, visitado abr. de 2025. dirección: <https://learn.microsoft.com/en-us/azure/ai-services/openai/reference>

- [23] Center for Internet Security. «CIS Controls Version 8,» CIS, visitado abr. de 2025. dirección: <https://www.cisecurity.org/controls/v8>
- [24] M. Kleppmann, *Designing Data-Intensive Applications*. O'Reilly Media, 2017.
- [25] I. Ward. «JSON Lines — a format for storing sequences of JSON values,» visitado abr. de 2025. dirección: <https://jsonlines.org/>
- [26] Chart.js Contributors. «Chart.js — Simple yet flexible JavaScript charting library,» visitado abr. de 2025. dirección: <https://www.chartjs.org/>
- [27] M. Fowler. «Mocks Aren't Stubs,» [martinfowler.com](https://martinfowler.com/articles/mocksArentStubs.html), visitado abr. de 2025. dirección: <https://martinfowler.com/articles/mocksArentStubs.html>

